


概率论与数理统计

心智模型手册 v2

随机对象、信息条件与分布变换的统一心智模型



概率论研究：当随机机制已知时，结果会怎样随机；数理统计研究：当机制未知、只看样本时，怎样反推机制。

使用说明：这不是公式册，而是“随机世界的操作系统”

本册的任务

概率统计最容易被学成一串公式：条件概率、Bayes、分布函数、二维密度、期望方差、中心极限定理、 $\chi^2/t/F$ 、最大似然、置信区间、假设检验。真正困难的却不是记住公式，而是判断：当前随机对象是什么？已经知道什么信息？应该改变哪个表示？目标究竟要概率、分布、数字特征，还是未知参数？

本册只承担四项稳定任务：

1. 建立概率论与数理统计的统一世界模型；
2. 解释教材各章在这个模型中的位置，以及为什么必须出现；
3. 建立高频概念边界，给出真正判据和题目信号；
4. 给出做题时可执行的识别、路径选择与校验协议。

具体计算技巧、题型变式和个人经验留给后续 Practice Layer 持续生长。

阅读本册时怎样使用箭头

本册中的箭头有三种含义，必须看上下文：

- $A \rightarrow B$ 若出现在“对象升级链”中，表示认知层次从 A 升级到 B，不是时间先后；
- $X \xrightarrow{g} Y$ 表示随机变量通过函数变换；
- $\text{Model} \rightarrow \text{Data}$ 或 $\text{Data} \rightarrow \text{Model}$ 表示推理方向。

任何箭头第一次出现后，本册都必须用文字解释其含义，而不是把符号本身当成解释。

目录

使用说明：这不是公式册，而是“随机世界的操作系统”	ii
第一章 总图：概率论和统计学其实是一个正问题和一个逆问题	1
1.1 概率论：已知机制，问结果怎样随机	1
1.2 统计学：只看到数据，问背后的机制是什么	1
1.3 对象升级链：同一个随机现象为什么会出现这么多概念	1
1.4 概率题反复出现的三种基本信息操作	2
1.4.1 Condition：加入信息，缩小有效随机世界	2
1.4.2 Marginalize：忽略某部分信息，把它的所有可能贡献加起来	2
1.4.3 Transform：换观察函数，重新搬运概率质量	3
1.5 两个母例：后面每一章都回到它们	3
1.6 本册后续章节与母模型的映射	4
第二章 随机事件与概率：先把“随机世界”和“已知信息”说清楚	5
2.1 随机试验、样本点、样本空间、事件是四个不同层次	5
2.2 事件运算不是符号游戏，而是语言翻译	5
2.3 概率公理真正保证了什么	6
2.4 古典概型、几何概型的共同本质：先确定“等可能”的基本单位	6
2.5 条件概率：已知信息以后，世界被重置	6
2.6 乘法公式、全概率、Bayes 是一条因果—证据链	7
2.7 独立性：知道一个事件以后，另一个概率不变	7
2.8 Bernoulli 重复试验：独立性第一次变成可计算结构	8
第三章 随机变量与一维分布：把随机世界压缩到数轴上	9
3.1 随机变量是观察函数，不是随机性的来源	9
3.2 分布：概率质量在取值空间上的安排	9
3.3 CDF：离散与连续的统一语言	9
3.4 Support：先找到随机变量真正可能出现的区域	10
3.5 常见离散分布：不要背名字，要记“生成机制”	10

3.6	常见离散分布：不要背名字，要记“生成机制”	10
3.7	常见连续分布：记住其“形状原因”	10
3.8	标准化：把“位置和尺度”从形状里拆出去	11
3.9	Poisson 近似 Binomial：近似来自结构，而不是公式相似	11
第四章	随机变量函数：Transform 是概率质量的重新映射	12
4.1	为什么 $Y = g(X)$ 不是“代入一个函数”这么简单	12
4.2	CDF 法：最稳健的通用思想	12
4.3	单调连续变换：密度中的 Jacobian 是“局部拉伸补偿”	12
4.4	离散型变换：把所有原像概率加起来	13
4.5	最大值、最小值常用 CDF，因为事件更容易拆	13
4.6	只求 $E[g(X)]$ 时，先问能否绕过完整分布	13
第五章	多维随机变量：真正新增的是“依赖结构”	14
5.1	从一个观察函数升级到多个观察函数	14
5.2	Joint：联合分布保存的是“共同状态”	14
5.3	Marginal：只看一个变量时，另一个维度被积分掉	14
5.4	Conditional：知道一个变量以后重新切片并归一化	15
5.5	Independence：条件化以后分布完全不变	15
5.6	Covariance 为零只消除了线性共同变化	15
5.7	两个随机变量的函数：先确定变换，再决定表示	15
5.8	Convolution：独立和的密度为何是“滑动重叠”	16
第六章	数字特征：什么时候不需要完整分布？	17
6.1	期望：对随机结果进行“概率加权平均”	17
6.2	期望的线性性是一条非常强的结构性捷径	17
6.3	方差：围绕期望的平方波动尺度	17
6.4	和的方差为什么比和的期望多一个 covariance	18
6.5	协方差与相关系数：只测线性共同变化	18
6.6	矩：用不同次幂查看分布的不同侧面	18
6.7	Chebyshev 不等式：只知道均值方差，也能控制尾部	18
第七章	大量重复：随机性为什么会同时产生“稳定”和“正态波动”	19
7.1	从单个随机变量转向随机变量序列	19
7.2	大数定律：平均会稳定到总体水平	19
7.3	Chebyshev 思路：为什么平均会越来越稳定	19
7.4	中心极限定理：剩余误差为什么近似正态	20

7.5	De Moivre–Laplace: Binomial 的正态近似	20
7.6	Levy–Lindeberg: 把 Bernoulli 经验推广到一般 iid 和	20
第八章	数理统计入口: 样本、统计量和抽样分布	21
8.1	总体不是“所有人”, 而是一个概率分布模型	21
8.2	简单随机样本: 重复抽样产生新的随机向量	21
8.3	统计量: 样本的函数, 但不能含未知参数	21
8.4	自由度: 为什么样本方差里出现 $n - 1$	22
8.5	χ^2 : 平方标准正态量的累积	22
8.6	t : 总体方差未知时, 用样本方差替代会多出额外不确定性	22
8.7	F : 两个独立方差尺度的比	22
8.8	正态总体为什么在统计教材里地位特殊	22
8.9	统计推断选择前, 先回答“未知量是谁、方差知道吗”	23
第九章	参数估计: 从“猜一个数”升级到“构造可评价的随机规则”	24
9.1	点估计首先分“怎么构造”和“怎么评价”	24
9.2	矩估计: 用样本矩匹配理论矩	24
9.3	最大似然: 选择最能解释已观测样本的参数	24
9.4	无偏性: 平均意义上有没有系统偏差	25
9.5	有效性: 同样无偏时, 谁波动更小	25
9.6	一致性: 样本量增大以后, 是否越来越接近真值	25
9.7	区间估计: 点估计必须配上不确定尺度	26
9.8	枢轴量: 把未知参数和已知抽样分布绑在一起	26
9.9	单个正态总体均值: σ 已知与未知为何对应不同标尺	26
9.10	单总体方差与双总体问题: 都是换一个 pivot	26
第十章	假设检验: 在一个假设世界里, 当前数据是否过于极端?	27
10.1	检验不是证明 H_0 对错, 而是控制错误风险的决策	27
10.2	显著性水平 α 控制的是第一类错误	27
10.3	单侧与双侧: 由备择方向决定拒绝域的位置	27
10.4	检验统计量的选择与区间估计共享同一套抽样分布	27
10.5	置信区间与双侧检验的对应关系	27
10.6	“不拒绝”绝不等于“证明原假设正确”	28
第十一章	概念边界: 真正区别、题目信号与错误后果	29
第十二章	统一做题控制: 概率统计真正应该怎样起手	31
12.1	第一层: 先判断题目在问哪种“输出”	31

12.2 第二层：识别当前随机对象	31
12.3 第三层：列出信息条件	31
12.4 第四层：选择最自然表示	31
12.5 第五层：识别当前操作	32
12.6 第六层：路径选择，不要多做无关中间量	32
12.7 第七层：执行过程中维护 support、参数范围和自由度	32
12.8 第八层：结果校验	32
12.9 四类典型断点如何修复	33
第十三章 两个母例的完整回放：真正把整门课串起来	34
13.1 Bernoulli 序列：从事件到统计推断	34
13.1.1 Stage 1: 事件	34
13.1.2 Stage 2: 随机变量	34
13.1.3 Stage 3: 分布与和	34
13.1.4 Stage 4: 数字特征	34
13.1.5 Stage 5: 样本比例	34
13.1.6 Stage 6: LLN 与 CLT 极限导出	34
13.1.7 Stage 7: 统计逆推与估计	35
13.2 正态总体：从模型结构到 N, χ^2, t, F 和推断全过程推演	35
13.2.1 Stage 1: 总体模型与独立抽样	35
13.2.2 Stage 2: 样本均值与样本方差的推导	35
13.2.3 Stage 3: 抽样分布 t 统计量的完整导出	35
13.2.4 Stage 4: 区间估计推导	35
13.2.5 Stage 5: 假设检验反证决策推演	35
附录 A 数学一概率论与数理统计完整覆盖清单	37
附录 B 一页压缩：概率统计最终应该留下什么	40

总图：概率论和统计学其实是一个正问题和一个逆问题

1.1 概率论：已知机制，问结果怎样随机

设随机模型由参数 θ 决定，例如硬币正面概率 p 、正态总体的 μ, σ^2 。概率论的典型方向是

$$\theta \text{ 或分布模型} \longrightarrow X, (X, Y), X_1 + \cdots + X_n \text{ 怎样分布}$$

这是一类**正问题 (forward problem)**：机制在左边，随机结果在右边。

例如已经知道

$$X_i \stackrel{iid}{\sim} \text{Bernoulli}(p),$$

那么我们可以推出成功次数

$$S_n = \sum_{i=1}^n X_i \sim B(n, p),$$

进一步求 $P(S_n \geq k)$ 、 $E(S_n)$ 、 $Var(S_n)$ ，或者在 n 很大时讨论正态近似。

1.2 统计学：只看到数据，问背后的机制是什么

统计学把方向倒过来：

$$x_1, \dots, x_n \longrightarrow \theta \text{ 可能是多少? 关于 } \theta \text{ 能作什么判断?}$$

例如不知道硬币的 p ，只观察到 100 次中 63 次正面。此时 p 是**固定但未知**的参数，63/100 是数据给出的信息。统计学要研究：怎样构造 $\hat{p}$ 、这个估计有多稳定、能给怎样的置信区间、能否拒绝 $p = 0.5$ 这样的假设。

概念边界：概率 $\neq$ 统计

两者不是“前半本书和后半本书”这么简单。概率的输入是模型、输出是随机结果；统计的输入是结果、输出是关于模型的推断。统计推断之所以可能，恰恰因为概率论已经告诉我们：**如果参数真是某个值，那么统计量会怎样随机。**

1.3 对象升级链：同一个随机现象为什么会出现这么多概念

整门课可以沿下面的对象链理解：

$$\text{Random Experiment} \rightarrow \Omega \rightarrow \text{Event} \rightarrow \text{Random Variable} \rightarrow \text{Distribution}$$

JointStructure → Feature → Sample → Statistic → Inference

这不是时间流程，而是描述同一随机现象时逐渐提高抽象层次。

层次	真正含义	教材内容	做题第一问
Random Experiment	可以在相同条件下重复、结果事先不唯一	随机试验	随机性来自哪里？
Ω	所有基本结果的集合	样本空间	所有可能结果列全了吗？
Event	Ω 的子集，是“我们关心的一类结果”	事件运算	“至少/恰好/同时/不发生”翻译成什么集合？
Random Variable	$X : \Omega \rightarrow \mathbb{R}$ ，给结果贴上数值标签	随机变量	我要观察随机结果的哪个数值特征？
Distribution	概率质量在 X 取值空间上的分配	分布律、CDF、PDF	概率质量落在哪里？support 是什么？
Joint Structure	多个随机观察量怎样共同变化	二维分布、条件/边缘、独立	知道一个变量会不会改变另一个？
Feature	用少数数字压缩完整分布	期望、方差、协方差	题目是否只要摘要而不需要完整分布？
Sample	从总体重复获得的随机变量组	简单随机样本	抽样前哪些量仍是随机的？
Statistic	样本的函数且不能含未知参数	$\bar{X}, S^2$ 、抽样分布	这个统计量在重复抽样中怎样随机？
Inference	根据统计量对参数作估计或检验	估计、区间、检验	数据究竟支持什么范围/决策？

1.4 概率题反复出现的三种基本信息操作

概率论里很多公式其实只是三种动作的不同实现。

1.4.1 Condition：加入信息，缩小有效随机世界

从 $P(A)$ 变成 $P(A \mid B)$ ，不是“多了一个竖线”，而是已知 B 发生以后，原来的有效世界从 Ω 缩小到 B ，并在 B 内重新归一化。

1.4.2 Marginalize：忽略某部分信息，把它的所有可能贡献加起来

例如联合密度 $f_{X,Y}$ 已知，只关心 X ：

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x,y) dy.$$

这里积分不是技巧，而是“现在不再区分 Y 到底取多少，把所有可能的 Y 情形都合并”。

1.4.3 Transform: 换观察函数，重新搬运概率质量

定义 $Y = g(X)$ 后，随机性并没有重新产生；只是我们从观察 X 改为观察 $g(X)$ 。所以要追踪：哪些 x 被映射到同一个 y ，原来的概率质量怎样合并或拉伸。

三个动作如何连接教材章节

- 全概率：对隐藏原因先 Condition，再把原因 Marginalize；
- Bayes：得到 evidence 后重新 Condition 到原因空间；
- 边缘分布：Marginalize 掉不关心的变量；
- 条件分布：Condition 到某个变量取值；
- $Y = g(X)$ 、 $X + Y$ 、 $\max(X, Y)$ ：Transform；
- 统计量 $T(X_1, \dots, X_n)$ ：也是 Transform，只不过输入变成整个样本向量。

1.5 两个母例：后面每一章都回到它们

贯穿例：母例 A：Bernoulli 序列

一次试验只有成功/失败，成功概率 p 。定义

$$X_i = \begin{cases} 1, & \text{第 } i \text{ 次成功,} \\ 0, & \text{失败.} \end{cases}$$

则 $X_i \sim \text{Bernoulli}(p)$ 。这个简单对象会依次生成：

$$\text{Event} \rightarrow X_i \rightarrow S_n = \sum X_i \rightarrow B(n, p) \rightarrow E/\text{Var} \rightarrow \bar{X} \rightarrow \text{LLN}/\text{CLT} \rightarrow \hat{p}.$$

后面我们会反复用它解释“随机变量为什么有用”“和的分布”“大数定律”“中心极限定理”“点估计”和“假设检验”。

贯穿例：母例 B：正态总体

设

$$X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2).$$

当 μ, σ^2 已知，这是概率模型；当参数未知时，样本用于反推它们。统计阶段将出现

$$\bar{X}, \quad S^2, \quad \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}, \quad \frac{(n-1)S^2}{\sigma^2},$$

进而自然出现 Normal、 χ^2 、 t 、 F 四类“概率标尺”。

1.6 本册后续章节与母模型的映射

章节	真正母问题	核心操作/对象
随机事件与概率	先怎样定义随机世界和信息？	Event, Condition
随机变量与分布	怎样把随机结果数值化？	$X : \Omega \rightarrow \mathbb{R}$, Distribution
随机变量变换	换观察对象后概率质量怎样搬运？	Transform
多维随机变量	多个随机量之间怎样共享信息？	Joint / Marginal / Conditional
数字特征	是否能不用完整分布，只保留重要摘要？	Expectation / Variance / Covariance
极限定理	大量重复为何出现稳定和正态波动？	Aggregate / Standardize / Approximate
抽样分布	统计量自己怎样随机？	Statistic as Random Variable
参数估计	怎样由样本构造参数信息？	Estimator / Pivot
假设检验	一个假设下当前数据是否太极端？	Null Model / Tail Probability

随机事件与概率：先把“随机世界”和“已知信息”说清楚

2.1 随机试验、样本点、样本空间、事件是四个不同层次

考虑掷两枚硬币。随机试验是“掷两枚硬币”；样本空间可以写为

$$\Omega = \{HH, HT, TH, TT\}.$$

HH 是一个样本点，而“恰好一枚正面”是事件

$$A = \{HT, TH\}.$$

概率 $P(A)$ 才是一个数。这个层级必须始终保持：

$$\boxed{\omega \in \Omega, \quad A \subseteq \Omega, \quad P(A) \in [0, 1].}$$

很多低级错误来自把集合和数混在一起，例如把 $A \cup B$ 写成概率加法，或者把 $P(A)$ 当事件继续取交集。

2.2 事件运算不是符号游戏，而是语言翻译

自然语言	集合表达	做题提醒
A 与 B 同时发生	$A \cap B$	“同时/且”不等于独立，独立是概率结构条件
A 或 B 至少一个发生	$A \cup B$	注意是否包含二者同时发生
A 不发生	A^c	“至少一个”常可转成“不是全不发生”
只有 A 发生	$A \cap B^c$	“只有”与“至少”不要混
A、B 恰好一个发生	$(A \cap B^c) \cup (A^c \cap B)$	两块互斥，可分别计算后相加

A 发生蕴含 B 发 $A \subseteq B$
生

概率上有 $P(A) \leq P(B)$

2.3 概率公理真正保证了什么

概率不是“感觉”，而是满足非负性、规范性和可列可加性的测度。数学一做题最常用的后果包括：

$$P(A^c) = 1 - P(A),$$

$$P(A \cup B) = P(A) + P(B) - P(A \cap B),$$

以及对互斥事件的直接相加。

概念边界：互斥 $\neq$ 独立

互斥是集合结构： $A \cap B = \emptyset$ 。独立是信息结构： $P(A \cap B) = P(A)P(B)$ 。如果 $P(A), P(B) > 0$ 且互斥，那么 $P(A \cap B) = 0$ ，却有 $P(A)P(B) > 0$ ，所以反而不独立。

题目信号：“不能同时发生/不相容”看互斥；“相互独立/一次结果不影响另一次”看独立。两类条件对应完全不同的计算动作。

2.4 古典概型、几何概型的共同本质：先确定“等可能”的基本单位

古典概型不是“排列组合公式”，而是样本空间有限且基本结果等可能时：

$$P(A) = \frac{|A|}{|\Omega|}.$$

真正难点往往是你选的基本结果是否等可能。例如抽球问题里，“抽到的颜色序列”通常不一定等可能，而“具体球的组合”可能等可能。

几何概型把“个数”换成长度、面积、体积等几何测度：

$$P(A) = \frac{m(A)}{m(\Omega)}.$$

所以二者共同的母模型是：

Choose an equiprobable representation $\rightarrow$ measure favorable region/measure whole region.

2.5 条件概率：已知信息以后，世界被重置

条件概率

$$P(A | B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

真正的含义是：已知 B 发生后，不再把 B^c 中的结果视为可能； B 变成新的有效样本空间，其总概率重新归一化为 1。

贯穿例：从 52 张牌中已知抽到红牌，求是红桃的概率

原世界里红桃 13 张，红牌 26 张。已知“红牌”以后，黑牌全部被排除，所以有效世界只剩 26 张红牌，其中 13 张红桃：

$$P(\heartsuit | Red) = \frac{13}{26} = \frac{1}{2}.$$

如果直接用 13/52，说明你虽然看见了“已知”，却没有真的更新样本空间。

2.6 乘法公式、全概率、Bayes 是一条因果—证据链

乘法公式把联合概率分解：

$$P(A \cap B) = P(A)P(B | A).$$

这可以理解为“先走到 A，再在 A 条件下走到 B”。

如果 $B_1, \dots, B_n$ 是完备事件组，事件 A 可以由多个互斥来源产生：

$$P(A) = \sum_i P(B_i)P(A | B_i).$$

这就是全概率：先按隐藏来源分层，再把来源 Marginalize 掉。

Bayes 则在观察到 A 后反推来源：

$$P(B_i | A) = \frac{P(B_i)P(A | B_i)}{\sum_j P(B_j)P(A | B_j)}.$$

贯穿例：三台机器与次品：全概率和 Bayes 为什么是一对

三台机器产量占比 0.2, 0.3, 0.5，次品率分别 0.01, 0.02, 0.03。随机抽一个产品：

- 问“抽到次品的概率”，是从来源到结果：用全概率；
- 已知“它是次品”，问“最可能来自哪台机器”，是从证据反推来源：用 Bayes。

同一棵概率树，方向不同，问题就不同。

2.7 独立性：知道一个事件以后，另一个概率不变

若 $P(B) > 0$ ，独立可写成

$$P(A | B) = P(A),$$

也等价于

$$P(A \cap B) = P(A)P(B).$$

前一个表达更接近直觉：B 提供的信息没有改变我们对 A 的不确定性。

多个事件独立必须严格区分“两两独立”和“相互独立”。数学一题目若明确给“相互独立”，可以对任意子集乘概率；只知道两两独立，不能自动把三个事件交集拆成三项乘积。

2.8 Bernoulli 重复试验：独立性第一次变成可计算结构

若进行 n 次相互独立且每次成功概率都为 p 的试验，成功次数 S_n 满足

$$P(S_n = k) = \binom{n}{k} p^k (1-p)^{n-k}.$$

这里组合数来自“哪些 k 次成功”的位置选择， $p^k(1-p)^{n-k}$ 来自某个具体成功/失败序列的概率。

本章做题控制链

Translate language → Event representation → Check information

Condition/Partition/Independence → Compute → Range check

先把自然语言变成事件，再判断是否新增了条件信息；不要一上来寻找公式。

随机变量与一维分布：把随机世界压缩到数轴上

3.1 随机变量是观察函数，不是随机性的来源

随机变量

$$X : \Omega \rightarrow \mathbb{R}$$

把每个样本点映射到一个实数。它做的是**数值化观察**：从复杂随机结果中提取我们关心的数值特征。

例如两枚硬币：

$$HH \mapsto 2, \quad HT \mapsto 1, \quad TH \mapsto 1, \quad TT \mapsto 0,$$

这里 $X = \text{“正面个数”}$ 。多个不同样本点可以映射到同一个 X 值，这正是“压缩”。

3.2 分布：概率质量在取值空间上的安排

离散型随机变量用分布律

$$P(X = x_i) = p_i$$

描述概率质量落在哪些点上；连续型随机变量若存在密度，则

$$P(a < X \leq b) = \int_a^b f(x) dx.$$

密度不是点概率，而是“单位长度附近的概率强度”。连续型随机变量满足 $P(X = a) = 0$ ，即使 $f(a)$ 很大也一样。

3.3 CDF：离散与连续的统一语言

分布函数

$$F(x) = P(X \leq x)$$

对所有随机变量都适用。它必须满足：单调不减、右连续、 $F(-\infty) = 0$ 、 $F(+\infty) = 1$ 。

对离散型，CDF 的跳跃量就是点概率；对绝对连续型，若可导，则

$$F'(x) = f(x).$$

因此 CDF 是“累积到 x 为止的概率”，PDF 则是“局部密度”。

概念边界：CDF ≠ PDF

F 本身就是概率，所以取值在 $[0,1]$ 且单调； f 可以大于 1，也不要求单调。题目若给一个候选函数问“能否成为密度”，检查的是 $f \geq 0$ 与总积分为 1；问“能否成为分布函数”，检查的是 CDF 四性质。

3.4 Support：先找到随机变量真正可能出现的区域

无论离散还是连续，做分布题先找 support。若密度写成分段函数，积分上下限必须同时受题目事件与 support 约束；二维题更是如此。

一个常见错误是：先套积分公式，再发现积分区域超出了密度非零区域。正确顺序应是：

Find support → intersect with event → integrate/sum.

3.5 常见离散分布：不要背名字，要记“生成机制”

3.6 常见离散分布：不要背名字，要记“生成机制”

分布	随机机制	最核心对象	高频信号
0-1	一次成败试验	指示变量	成功/失败
Binomial	固定 n 次独立同概率试验	成功总次数	n 固定、每次 p
Geometric	不断重复直到首次成功	等待次数	“第一次成功在第几次”
Hypergeo.	有限总体不放回抽样	抽中成功对象数	不放回、总体成功数固定
Poisson	区间内稀疏事件计数模型	事件次数	到达、事故、缺陷、 λ


贯穿例：Binomial 和 Hypergeometric 为什么不能只看“成功次数”

两题都可能问“抽中红球个数”。若每次抽后放回，或等价地每次成功概率保持不变且相互独立，容易得到 Binomial；若从有限总体不放回，后一次概率依赖前一次结果，应是 Hypergeometric。真正判据是独立同概率结构，而不是表面上都在“数成功次数”。

3.7 常见连续分布：记住其“形状原因”

分布	核心机制/形状	关键结构	做题信号
Uniform	区间内没有位置偏好	密度常数	随机点、等可能落在区间

Exponential	Poisson 到达之间的等待时间模型	无记忆性	等待下一事件、寿命模型
Normal	大量小扰动叠加的经典模型	对称、标准化	给 μ, σ 、线性组合、近似



3.8 标准化：把“位置和尺度”从形状里拆出去

若 $X \sim N(\mu, \sigma^2)$ ，标准化

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

做了两件事：先减均值消除位置，再除标准差消除尺度。标准化不是正态分布专属思维，后面 t 、 χ^2 、 F 、CLT 和假设检验都会反复做类似的“构造无量纲概率标尺”。

3.9 Poisson 近似 Binomial：近似来自结构，而不是公式相似

当 n 大、 p 小、 $np = \lambda$ 保持在适中尺度时，二项分布可以用 Poisson 近似。这对应“很多机会，每次事件很稀有，总期望次数有限”的结构。若 p 并不小，机械换成 Poisson 通常不合理。

本章识别链

Discrete/Continuous → Generation mechanism → Support

Distribution representation → Probability calculation

先识别“如何生成”，再识别“叫什么分布”。

随机变量函数：Transform 是概率质量的重新映射

4.1 为什么 $Y = g(X)$ 不是“代入一个函数”这么简单

定义 $Y = g(X)$ 后，同一个底层样本点 ω 同时给出 $X(\omega)$ 和 $Y(\omega) = g(X(\omega))$ 。随机性没有变化，变化的是观察方式。

核心问题变成：

Which x map to the same y ? How does probability mass move?

4.2 CDF 法：最稳健的通用思想

求 Y 的分布，可以从

$$F_Y(y) = P(Y \leq y) = P(g(X) \leq y)$$

出发，把关于 Y 的事件重新翻译成关于 X 的事件，再用 X 的已知分布计算。这种方法对单调和非单调函数都适用，只是事件区域翻译难度不同。

贯穿例： $Y = X^2$ 为什么必须先看原像

若 $Y = X^2$ ，则

$$\{Y \leq y\} = \{-\sqrt{y} \leq X \leq \sqrt{y}\}, \quad y \geq 0.$$

一个 $y > 0$ 通常有两个原像 $\pm\sqrt{y}$ 。如果你只保留一个分支，就会漏掉一半概率贡献。

4.3 单调连续变换：密度中的 Jacobian 是“局部拉伸补偿”

若 $Y = g(X)$ 单调可逆， $x = g^{-1}(y)$ ，密度满足

$$f_Y(y) = f_X(g^{-1}(y)) \left| \frac{d}{dy} g^{-1}(y) \right|.$$

绝对值导数不是凭空出现的公式，它补偿坐标变换造成的局部长短伸缩，保证概率质量守恒。

4.4 离散型变换：把所有原像概率加起来

若 $Y = g(X)$ 是离散型，则

$$P(Y = y) = \sum_{x:g(x)=y} P(X = x).$$

这和连续型多分支变换的思想完全一致：同一个输出值的所有来源都要汇合。

4.5 最大值、最小值常用 CDF，因为事件更容易拆

对独立随机变量 $X_1, \dots, X_n$ ：

$$P(\max X_i \leq y) = P(X_1 \leq y, \dots, X_n \leq y),$$

独立时可以变成 CDF 乘积。类似地，最小值常用补事件：

$$P(\min X_i > y) = P(X_1 > y, \dots, X_n > y).$$

所以“最大/最小值分布”不是新公式，而是寻找一个容易用交集表达的事件。

4.6 只求 $E[g(X)]$ 时，先问能否绕过完整分布

若目标只是数字特征，LOTUS 思想允许直接在 X 的原分布上计算：

$$E[g(X)] = \sum_x g(x)P(X = x)$$

或

$$E[g(X)] = \int g(x)f_X(x) dx.$$

这是一条非常重要的做题路径规则：

Target is expectation $\Rightarrow$ do not automatically derive full distribution first.

数学一训练：路径比较

已知 $X \sim N(0, 1)$ ，求 $E(X^2)$ 。直接用 $Var(X) = E(X^2) - (EX)^2$ 得到 1，明显比先求 $Y = X^2$ 的 $\chi^2(1)$ 分布再积分更短。心智模型不仅帮助“会做”，也帮助避免无效路径。

多维随机变量：真正新增的是“依赖结构”

5.1 从一个观察函数升级到多个观察函数

同一个随机世界上定义

$$X(\omega), \quad Y(\omega),$$

得到随机向量 (X, Y) 。现在问题不再只是各自怎么分布，而是：知道 Y 的信息，会不会改变我们对 X 的分布判断？

因此二维随机变量的母链应记为：

$$\text{Joint} \rightarrow \text{Marginal} \rightarrow \text{Conditional} \rightarrow \text{Dependence}.$$

5.2 Joint：联合分布保存的是“共同状态”

联合分布函数

$$F_{X,Y}(x, y) = P(X \leq x, Y \leq y)$$

或者联合密度 $f_{X,Y}(x, y)$ 描述 (X, Y) 在二维空间里的概率质量。连续型题首先要画 support，因为概率事件本质上是二维区域积分：

$$P((X, Y) \in D) = \iint_D f_{X,Y}(x, y) dx dy.$$

5.3 Marginal：只看一个变量时，另一个维度被积分掉

若只关心 X ，对所有可能的 Y 求和/积分：

$$f_X(x) = \int_{-\infty}^{\infty} f_{X,Y}(x, y) dy.$$

这不是“二维密度的固定公式”，而是 **Marginalize**：不再区分 Y 取值，把所有贡献合并到同一个 x 上。

贯穿例：三角形 support 为什么比积分本身更重要

若联合密度只在 $0 < y < x < 1$ 上非零，求 $f_X(x)$ 时，对固定 x ， y 的允许范围是 $0 < y < x$ ，而不是机械积分 0 到 1。求 $f_Y(y)$ 时，对固定 y ， x 的范围又变成 $y < x < 1$ 。边缘化上下限来自 support 截面，而不是背公式。

5.4 Conditional: 知道一个变量以后重新切片并归一化

连续型条件密度

$$f_{X|Y}(x|y) = \frac{f_{X,Y}(x,y)}{f_Y(y)}$$

可以理解为：把联合密度在 $Y = y$ 的“切片”取出来，再让这条切片总概率归一化为 1。

因此条件分布和一维条件概率是同一种动作：加入信息以后，重新定义有效随机世界。

5.5 Independence: 条件化以后分布完全不变

独立最强的表达是：知道 Y 不提供关于 X 的额外分布信息。于是

$$f_{X|Y}(x|y) = f_X(x),$$

并等价于（适当条件下）

$$f_{X,Y}(x,y) = f_X(x)f_Y(y).$$

5.6 Covariance 为零只消除了线性共同变化

协方差

$$\text{Cov}(X,Y) = E[(X - EX)(Y - EY)]$$

只测量线性共同变化。可能存在非常强的非线性依赖，但 covariance 仍为 0。

例如若 X 关于 0 对称，令 $Y = X^2$ ，则 Y 完全由 X 决定，显然不独立；但在许多对称分布下 $E(X^3) = 0$ ，可能得到 $\text{Cov}(X,Y) = 0$ 。

概念边界：独立 $\neq$ 不相关

独立通常推出不相关（相关矩存在时）；不相关一般不能推出独立。**题目信号**：只给 $\text{Cov} = 0$ 或 $\rho = 0$ ，禁止直接把联合密度拆成乘积。若额外给“二维正态”，才有重要特殊结论：不相关可推出独立。

5.7 两个随机变量的函数：先确定变换，再决定表示

数学一高频目标包括 $X+Y$ 、 $X-Y$ 、 XY 、 $\max(X,Y)$ 、 $\min(X,Y)$ 。不要把它们看成五套公式，而要先问：

1. 新随机变量 $Z = g(X,Y)$ 的事件 $\{Z \leq z\}$ 在 (x,y) 平面是什么区域？
2. 是直接做二维积分更简单，还是利用独立性做 convolution 更简单？
3. 若只求 EZ 或 $\text{Var}Z$ ，能否完全绕过 f_Z ？

5.8 Convolution: 独立和的密度为何是“滑动重叠”

若 X, Y 独立且连续, $Z = X + Y$, 则

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x)f_Y(z-x)dx.$$

对固定 z , 所有满足 $x+y=z$ 的组合都会对 $Z=z$ 附近的概率贡献质量。卷积就是沿直线 $x+y=z$ 汇总所有来源。

二维题统一草稿动作

先画 support, 再画事件区域; 若求边缘, 画“固定 x 或固定 y 的截线”; 若求函数分布, 画 $g(x, y) \leq z$ 的区域。二维概率题最常见的失败不是积分不会, 而是区域没有画清。

数字特征：什么时候不需要完整分布？

6.1 期望：对随机结果进行“概率加权平均”

离散型

$$E[X] = \sum_x xP(X = x),$$

连续型

$$E[X] = \int xf(x) dx.$$

它可以理解为长期平均，也可看成概率质量的平衡中心。但期望不一定是最可能值，也不一定属于随机变量实际 support。

6.2 期望的线性性是一条非常强的结构性捷径

$$E(aX + bY) = aEX + bEY$$

不需要 X, Y 独立。这一点极其重要，因为很多“总次数/总收益/总损失”的期望可以拆成许多指示变量之和，而完全不必求它们的联合分布。

贯穿例：指示变量法：为什么相关事件也能轻松算期望

设 I_i 表示第 i 个对象是否满足某条件，则总个数 $N = \sum I_i$ 。即使 I_i 彼此相关，仍有

$$E[N] = \sum_i E[I_i] = \sum_i P(I_i = 1).$$

所以“求计数的期望”常常先拆成指示变量，而不是先求 N 的完整分布。

6.3 方差：围绕期望的平方波动尺度

定义

$$\text{Var}(X) = E[(X - EX)^2].$$

计算时常用

$$\text{Var}(X) = E(X^2) - (EX)^2.$$

方差不是“平均误差”而是平方尺度，因此 $\text{Var}(aX + b) = a^2\text{Var}(X)$ 。

6.4 和的方差为什么比和的期望多一个 covariance

$$\text{Var}(X + Y) = \text{Var}X + \text{Var}Y + 2\text{Cov}(X, Y).$$

原因是平方展开中出现交叉项。独立时 covariance 为 0，所以方差可直接相加；但线性期望从来不需要独立。

概念边界：“期望可拆”与“方差可拆”不是同一条件

看到 $E(X + Y)$ 可以直接拆，不查独立；看到 $\text{Var}(X + Y)$ 必须检查 covariance/independence。很多选择题就是在考这条边界。

6.5 协方差与相关系数：只测线性共同变化

协方差受单位影响，相关系数

$$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

把尺度归一化到 $[-1, 1]$ ，便于比较线性关系强弱。 $|\rho| = 1$ 表示几乎处处线性关系，而 $\rho = 0$ 只表示没有线性相关。

6.6 矩：用不同次幂查看分布的不同侧面

原点矩 $E(X^k)$ 、中心矩 $E[(X - EX)^k]$ 是对分布的不同摘要。数学一主要掌握一阶、二阶及协方差等常用量。学习时不要把“矩”当额外公式，它只是“对 $g(X) = X^k$ 求期望”。

6.7 Chebyshev 不等式：只知道均值方差，也能控制尾部

若 $EX = \mu$ 、 $\text{Var}X = \sigma^2$ ，则

$$P(|X - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{\varepsilon^2}.$$

它的意义在于：即使不知道完整分布，仅靠均值和方差，也能给偏离均值的概率一个通用上界。这个思想直接通向大数定律：平均以后方差缩小，于是远离真实均值的概率被压低。

数字特征题路径规则

先看目标是否只要求 $E, \text{Var}, \text{Cov}$ 。若是，优先使用线性性、LOTUS、方差展开、独立性等直接结构；只有这些信息不足时，才考虑先求完整分布。

大量重复：随机性为什么会同时产生“稳定”和“正态波动”

7.1 从单个随机变量转向随机变量序列

前面研究一个 X 或一对 (X, Y) 。现在考虑

$$X_1, X_2, \dots, X_n$$

以及它们的和与平均：

$$S_n = \sum_{i=1}^n X_i, \quad \bar{X}_n = \frac{S_n}{n}.$$

核心问题变成：当 $n \rightarrow \infty$ 时，大量随机波动叠加后会出现什么规律？

7.2 大数定律：平均会稳定到总体水平

以 iid 情形为例，若 $EX_i = \mu$ ，在适当条件下

$$\bar{X}_n \xrightarrow{P} \mu.$$

大数定律回答的是：平均以后靠近哪里？

Bernoulli 情形中， $\bar{X}_n$ 正好是成功频率，所以

$$\frac{S_n}{n} \rightarrow p$$

解释了“频率为什么稳定到概率”。这不是概率的定义，而是模型下的极限定理。

7.3 Chebyshev 思路：为什么平均会越来越稳定

若 X_i iid，方差为 σ^2 ，则

$$\text{Var}(\bar{X}_n) = \frac{\sigma^2}{n}.$$

于是 Chebyshev 给出

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\sigma^2}{n\varepsilon^2} \rightarrow 0.$$

这展示了一个非常重要的机制：独立平均把随机波动尺度从 σ 压到 $\sigma/\sqrt{n}$ 。

7.4 中心极限定理：剩余误差为什么近似正态

LLN 说 $\bar{X}_n$ 靠近 μ ，但并没有告诉你剩余误差长什么样。CLT 进一步研究标准化波动：

$$\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}} \Rightarrow N(0, 1).$$

所以 CLT 回答的是：围绕稳定点的剩余随机波动呈什么形状？

概念边界：LLN $\neq$ CLT

LLN 是“位置”： $\bar{X}_n$ 去哪里；CLT 是“形状”：标准化后的误差怎样分布。题目问极限概率趋近 0/1、频率是否稳定，多半看 LLN；题目给大 n 并要求近似计算一个和或均值落在区间的概率，多半看 CLT。

7.5 De Moivre–Laplace：Binomial 的正态近似

若 $S_n \sim B(n, p)$ ，则在合适条件下

$$\frac{S_n - np}{\sqrt{np(1-p)}} \approx N(0, 1).$$

这就是 Bernoulli 母例从精确二项分布走向大样本近似的桥梁。离散变量用连续正态近似时，要注意题设和教材口径下的连续性校正习惯。

7.6 Levy–Lindeberg：把 Bernoulli 经验推广到一般 iid 和

数学一要求了解 iid 中心极限定理。真正要留下的不是名字，而是结构：许多独立、同分布、具有有限均值方差的随机变量相加后，只要适当中心化和标准化，其总和的形状趋向正态。

贯穿例：Bernoulli 母例第一次完成“概率到统计”的桥

对 $X_i \sim \text{Bernoulli}(p)$ ，有 $EX_i = p$ 、 $\text{Var} X_i = p(1-p)$ 。因此

$$\bar{X} = \frac{S_n}{n}$$

既是成功频率，也是未知 p 的天然估计量。LLN 解释它为什么会靠近 p ；CLT 解释它大样本下的误差规模约为 $\sqrt{p(1-p)/n}$ 。统计推断正是从这里开始：稳定性保证“可估”，抽样波动描述“估得有多准”。

数理统计入口：样本、统计量和抽样分布

8.1 总体不是“所有人”，而是一个概率分布模型

在统计学语言中，总体可以理解为产生观测值的分布。参数 θ 决定分布的某些性质，例如正态总体的 μ, σ^2 。参数在频率学派中是固定但未知的。

8.2 简单随机样本：重复抽样产生新的随机向量

简单随机样本

$$X_1, \dots, X_n$$

满足独立且与总体同分布。抽样前它们仍是随机变量；真正观察后得到具体值

$$x_1, \dots, x_n.$$

这条“抽样前/抽样后”的边界必须始终保持。

8.3 统计量：样本的函数，但不能含未知参数

统计量写成

$$T = T(X_1, \dots, X_n).$$

例如

$$\bar{X} = \frac{1}{n} \sum X_i, \quad S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2.$$

它们之所以重要，是因为统计量本身也随机，所以我们可以研究其**抽样分布**。

概念边界：Parameter $\neq$ Statistic $\neq$ Estimator $\neq$ Estimate

μ, σ^2, p 是固定未知参数； $\bar{X}, S^2$ 是随机统计量；若 $\bar{X}$ 被拿来估计 μ ，它又承担 estimator 的角色；真正代入数据得到 2.73 后，这个数才是 estimate。题目问“无偏性”时，必须对 estimator 求期望，不能对已观察的数字谈随机性。

8.4 自由度：为什么样本方差里出现 $n - 1$

样本偏差满足

$$\sum_{i=1}^n (X_i - \bar{X}) = 0.$$

n 个偏差之间存在一个线性约束，所以只有 $n - 1$ 个独立自由方向。这是“自由度”最直观的来源。它会直接进入 χ^2, t, F 分布参数。

8.5 χ^2 ：平方标准正态量的累积

若 $Z_1, \dots, Z_k \stackrel{iid}{\sim} N(0, 1)$ ，则

$$\sum_{i=1}^k Z_i^2 \sim \chi^2(k).$$

对正态总体，有

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1).$$

所以 χ^2 是“样本方差相对总体方差的标准化波动标尺”。

8.6 t ：总体方差未知时，用样本方差替代会多出额外不确定性

若总体正态，则

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

如果 σ 已知，分母是固定尺度，使用 Normal；如果 σ 未知，只能用随机的 S 替代，于是概率标尺变成 t 。所以 t 分布不是“样本量小就用”的机械规则，真正原因是正态总体下总体方差未知，分母自身带来额外随机性。

8.7 F ：两个独立方差尺度的比

若两个独立 χ^2 变量分别除以自由度后作比，得到 F 分布。正态总体比较两个方差时，自然出现

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2}.$$

因此 F 的核心语义是“两个方差尺度的相对大小”。

8.8 正态总体为什么在统计教材里地位特殊

不是因为所有现实总体都正态，而是因为正态模型有极强的闭合结构：样本均值仍正态，样本均值与样本方差独立，样本方差标准化后为 χ^2 。这些性质使区间估计和假设检验可以得到精确有限样本分布。

贯穿例：正态母例的抽样分布骨架

若 $X_i \overset{iid}{\sim} N(\mu, \sigma^2)$:

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$
$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1),$$

并且 $\bar{X}$ 与 S^2 独立。因此

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

这三条不是三个孤立公式，而是同一个正态总体结构的连续结果。

8.9 统计推断选择前，先回答“未知量是谁、方差知道吗”

目标	先检查条件	核心标尺	第一动作
单总体均值	正态? σ^2 已知?	N 或 t	标准化 $\bar{X}$
单总体方差	总体正态?	χ^2	标准化 S^2
两总体均值差	独立? 方差已知/未知及关系?	Normal / t	构造均值差枢轴
两总体方差比	两总体正态且独立?	F	构造方差比

参数估计：从“猜一个数”升级到“构造可评价的随机规则”

9.1 点估计首先分“怎么构造”和“怎么评价”

点估计不是找到一个看起来合理的数字，而是构造

$$\hat{\theta} = T(X_1, \dots, X_n)$$

来估计未知参数 θ 。构造以后还要研究这个随机规则在重复抽样中的表现。

9.2 矩估计：用样本矩匹配理论矩

若总体矩

$$E(X^k) = m_k(\theta)$$

含未知参数，就用样本矩

$$\frac{1}{n} \sum X_i^k$$

去匹配。其思想是：总体分布的数字特征由参数决定，而样本矩是这些数字特征的可观测近似。

贯穿例：Exponential(λ) 的矩估计

若参数化采用 $EX = 1/\lambda$ ，则令

$$\bar{X} = \frac{1}{\lambda}$$

得到

$$\hat{\lambda}_{MM} = \frac{1}{\bar{X}}.$$

这不是死记公式，而是“样本平均匹配总体平均”。

9.3 最大似然：选择最能解释已观测样本的参数

样本独立时 likelihood 通常写为

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta).$$

MLE 选择使当前样本最可能出现的参数：

$$\hat{\theta} = \arg \max_{\theta} L(\theta).$$

常取 $\log$ 把乘积变成和，是为了简化计算，不改变最大点。

MLE 完整动作协议

Parameter domain $\rightarrow$ Likelihood $\rightarrow \log L \rightarrow$ Candidate extrema

Boundary/support check $\rightarrow$ Return to parameter meaning

特别注意：若 support 本身依赖 θ ，不能只求导而忽略参数可行域和边界。

贯穿例：Bernoulli 母例：MLE 为什么得到样本比例

若 $X_i \sim \text{Bernoulli}(p)$ ，观测成功数 $S_n = \sum x_i$ ，则

$$L(p) = p^{S_n} (1-p)^{n-S_n}.$$

取对数求极值可得

$$\hat{p} = \frac{S_n}{n} = \bar{X}.$$

所以样本比例同时是最自然的频率估计、矩估计和 MLE；前面的 LLN 又解释了它为什么随 n 增大靠近真实 p 。

9.4 无偏性：平均意义上有没有系统偏差

若

$$E_{\theta}(\hat{\theta}) = \theta,$$

称估计量无偏。注意 expectation 是对“重复抽样产生的 $\hat{\theta}$ 分布”求平均，而不是对参数求期望。

9.5 有效性：同样无偏时，谁波动更小

若两个无偏估计量都对准同一个参数，方差更小者更集中，通常认为更有效。这里比较的是 sampling variance。

9.6 一致性：样本量增大以后，是否越来越接近真值

一致性研究

$$\hat{\theta}_n \xrightarrow{P} \theta.$$

它是大样本性质，与“有限 n 时是否无偏”不是一回事。一个估计量可以有小偏差但一致，也可能无偏却方差下降很慢。

9.7 区间估计：点估计必须配上不确定尺度

单个数不能告诉你“估得有多准”。区间估计构造随机区间

$$[L(X), U(X)]$$

使

$$P_{\theta}\{L(X) \leq \theta \leq U(X)\} = 1 - \alpha.$$

频率学派下 θ 固定，随机的是区间构造程序。长期重复抽样时，大约 $1 - \alpha$ 的区间覆盖真实参数。

9.8 枢轴量：把未知参数和已知抽样分布绑在一起

区间估计最核心的思路不是背四个公式，而是构造一个：

1. 含待估参数；
2. 分布已知；
3. 分布不再依赖未知参数（或可控制）；

的量，即 pivot。然后把一个概率不等式反解成参数范围。

9.9 单个正态总体均值： σ 已知与未知为何对应不同标尺

若 σ 已知：

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1).$$

若 σ 未知：

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

所以选择区间公式之前，真正第一问是：分母尺度是已知常数还是由样本估出来的随机量？

9.10 单总体方差与双总体问题：都是换一个 pivot

正态总体方差用 χ^2 ；两个独立正态总体的方差比用 F ；两个均值差根据方差已知/未知以及题设关系构造相应 pivot。这里不把所有公式塞入心智手册，但必须留下“先识别未知量与条件，再选抽样标尺”的决策结构。

数学一训练：估计题不要从“该用什么公式”开始

先写：未知参数是谁？当前有哪些统计量？总体是否正态？方差是否已知？题目要点估计还是区间？然后才选 MoM/MLE 或 $N/t/\chi^2/F$ 。这一步能避免大部分“公式其实背对了，但条件用错”的失分。

假设检验：在一个假设世界里，当前数据是否过于极端？

10.1 检验不是证明 H_0 对错，而是控制错误风险的决策

假设检验先规定原假设 H_0 和备择假设 H_1 。然后在 H_0 假定为真的世界里研究某个统计量的分布，并把“太不符合 H_0 的观测值”划入拒绝域。

所以完整逻辑是：

$H_0 \rightarrow \text{sampling distribution under } H_0 \rightarrow \text{rejection region} \rightarrow \text{observed statistic} \rightarrow \text{decision.}$

10.2 显著性水平 α 控制的是第一类错误

第一类错误： H_0 为真却拒绝；第二类错误： H_0 为假却未拒绝。显著性水平 α 用来控制第一类错误概率，不是“ H_0 为真的概率”，也不是“结论出错概率”。

10.3 单侧与双侧：由备择方向决定拒绝域的位置

如果 $H_1: \mu > \mu_0$ ，极端证据在右尾；若 $H_1: \mu < \mu_0$ ，在左尾；若 $H_1: \mu \neq \mu_0$ ，两侧都算偏离。题目里“是否增大/是否降低/是否改变”就是方向信号。

10.4 检验统计量的选择与区间估计共享同一套抽样分布

单个正态总体均值： σ 已知用 Z ，未知用 t ；方差用 χ^2 ；两个方差比用 F 。区别不是数学工具变了，而是区间估计把概率不等式反解成参数范围，假设检验把同一标尺转成拒绝/不拒绝规则。

10.5 置信区间与双侧检验的对应关系

在常见双侧情形下，若假设值 θ_0 落在 $1 - \alpha$ 置信区间外，则相应显著性水平 α 的双侧检验会拒绝 $H_0: \theta = \theta_0$ 。这个对应帮助理解两个章节为什么总使用同一批分位数。

贯穿例：正态均值检验：真正做的是“标准化后看有多极端”

设总体正态、 σ 已知，检验 $H_0: \mu = \mu_0$ 。在 H_0 下

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1).$$

观测到的 z 值越远离 0，说明样本均值和 H_0 预期越不相容。双侧检验就是看 $|z|$ 是否进入两端低概率区。

10.6 “不拒绝”绝不等于“证明原假设正确”

数据证据不足以拒绝 H_0 ，可能是 H_0 确实合理，也可能只是样本量太小、检验功效不足。因此规范表达是“在显著性水平 α 下不拒绝 H_0 ”，而不是“接受 H_0 为真”。

假设检验七步

1. 写清 H_0, H_1 和方向；
2. 确认总体、独立性、正态性和已知/未知条件；
3. 在 H_0 下构造统计量；
4. 写出该统计量在 H_0 下的分布；
5. 根据 α 和单/双侧确定拒绝域；
6. 计算观测统计量并比较；
7. 用题目语言写结论，不把“不拒绝”写成“证明成立”。

概念边界：真正区别、题目信号与错误后果

概念 A	概念 B	真正判据	题目信号	混淆后典型错误
样本点	≠事件 / 概率	结果 / 结果集合 / 数值测度	“事件 A”“求 $P(A)$ ”	把集合运算和数值运算混用
互斥	≠独立	不能同时发生 / 知道一个不改变另一个概率	“不相容”/“相互独立”	错把交概率写成乘积或 0
条件概率	≠联合概率	条件世界重新归一化 / 同时发生	“已知 B”	漏除 $P(B)$
全概率	≠Bayes	原因到结果 / 结果反推原因	“总体概率”/“已知发生”	推理方向反了
随机变量	≠样本点	观察函数 / 一次具体结果	$X(\omega)$	把随机变量当结果集合
CDF	≠PDF	累积概率 / 局部密度	$F(x) / f(x)$	把 $f(a)$ 当点概率
离散型	≠连续型	概率质量集中于点 / 用密度积分	分布律/密度	连续型算 $P(X = a)$ 非零
Binomial	≠Hypergeometric	独立同概率重复 / 有限总体不放回	放回/不放回	错假设独立
Joint	≠Marginal	保留所有变量 / 忽略其他变量	“联合”“边缘”	忘记积分/求和掉其他变量
Marginal	≠Conditional	忽略变量 / 已知变量后重新归一化	“只求 X”/“给定 $Y=y$ ”	把积分和除法混用
独立	≠不相关	分布完全解耦 / 仅线性 covariance 为 0	$Cov = 0$ 、 $\rho = 0$	直接推出联合密度乘积

$E(X + Y) \neq Var(X + Y)$		期望线性不需独立 / 方差需 covariance	求均值或方差	无条件把方差相加
LLN	$\neq$ CLT	稳定位置 / 标准化波动形状	“趋于”/“大样本近似概率”	错选定理
参数	$\neq$ 统计量	固定未知 / 抽样前随机	$\mu, \sigma^2 / \bar{X}, S^2$	把参数当随机变量求概率
统计量	$\neq$ 估计量	任意样本函数 / 用于估参数的统计量	“统计量”/“估计 θ ”	混淆任务角色
估计量	$\neq$ 估计值	抽样前随机规则 / 数据代入后的数值	无偏性/给定样本	对具体数值讨论 expectation
无偏	$\neq$ 一致	有限样本平均无偏差 / 大样本趋于真值	“无偏”/“相合”	把不同评价标准当同义词
Z	$\neq t$	总体方差已知 / 用样本方差替代未知方差	σ known/unknown	机械按样本量选分布
χ^2	$\neq F$	单方差标准化 / 两个独立方差比	单总体方差/方差比	标尺选错
置信水平	$\neq$ 覆盖概率	随机区间的长期覆盖率 / 参数固定	“95% CI”	错解频率学派区间
显著性水平	$\neq P(H_0 \text{真})$	第一类错误控制 / 后验概率不是本课程对象	$\alpha = 0.05$	把 0.05 解释成原假设真概率
不拒绝	$\neq$ 接受为真	证据不足以拒绝 / 逻辑证明成立	“未落入拒绝域”	结论表述过强

统一做题控制：概率统计真正应该怎样起手

12.1 第一层：先判断题目在问哪种“输出”

概率统计做题最先不是识别公式，而是识别目标类型：

- 概率数值 $P(A)$;
- 一个分布/CDF/PDF;
- 数字特征 E, Var, Cov ;
- 大样本近似概率;
- 参数的点估计;
- 参数的区间;
- 一个假设是否被拒绝。

目标不同，最短路径完全不同。

12.2 第二层：识别当前随机对象

问自己：现在处理的是 Event、 X 、 (X, Y) 、 $g(X, Y)$ 、样本 $X_1, \dots, X_n$ ，还是统计量 T ？同一个符号若对象层级判断错，后面的所有公式都会错位。

12.3 第三层：列出信息条件

显式标记：条件事件、independence、iid、support、参数已知/未知、总体是否正态、样本是否独立。数学一概率统计很多题真正考的就是“你有没有看见条件”。

12.4 第四层：选择最自然表示

问题类型	优先表示	为什么
事件关系	集合/Venn/概率树	保持“且或非、来源、条件”清晰

一维分布	分布律 / CDF / PDF	根据离散/连续和目标选择
二维概率	support + 平面区域	积分上下限来自几何区域
函数分布	CDF 事件反推或 Jacobian	追踪原像
和的分布	convolution / 二维区域	汇总所有来源
只求数字特征	expectation / variance identities	避免无谓求完整分布
极限定理	标准化后的和/均值	对准 LLN/CLT 的对象
估计/检验	statistic + sampling distribution	统计推断靠抽样分布提供标尺

12.5 第五层：识别当前操作

问：是在 Condition、Marginalize、Transform、Aggregate、Standardize、Approximate 还是 Infer?

其中 Aggregate/Standardize 是后半程高频动作：大量样本先求和/平均，再减去中心、除以尺度，使其进入一个已知参考分布。

12.6 第六层：路径选择，不要多做无关中间量

三个典型反例：

- 只求 $E[g(X)]$ ，不必先求 $g(X)$ 的分布；
- 已知联合密度只求 $P((X,Y) \in D)$ ，不必先求边缘分布；
- 要估计 μ ，若抽样分布已知，直接构造 pivot，不必先“求 $\bar{X}$ 的具体密度表达式”。

12.7 第七层：执行过程中维护 support、参数范围和自由度

概率题常见执行断点不是积分不会，而是积分区域丢失；MLE 常见断点是忘记参数定义域；统计题常见断点是自由度、单/双侧、分位数方向错。它们都属于“状态维护问题”。

12.8 第八层：结果校验

概率统计八项校验

1. 概率是否落在 $[0, 1]$?
2. 分布律概率和/密度总积分是否为 1?
3. CDF 是否单调、右连续、两端极限正确?
4. support 是否与题意一致?

5. 方差是否非负，相关系数是否在 $[-1, 1]$?
6. 估计量表达式是否偷偷含未知参数?
7. 自由度、分位数方向、单/双侧是否与题设一致?
8. 最终统计结论是否用“拒绝/不拒绝”而不是过度表述?

12.9 四类典型断点如何修复

断点	典型表现	真正原因	修复动作
识别断点	看见积分就直接算	没判断随机对象和目标	先写 Target/Object/Information
路径断点	明明只求期望却先求完整分布	缺目标驱动的路线选择	先问能否 LOTUS/线性性直接到目标
执行断点	二维积分上下限反复错	support 没画/截面没维护	强制画区域并标固定变量截线
检查断点	得到概率 > 1 仍继续	缺范围和归一化意识	结束前跑八项校验

两个母例的完整回放：真正把整门课串起来

13.1 Bernoulli 序列：从事件到统计推断

13.1.1 Stage 1: 事件

一次试验成功事件 A , $P(A) = p$ 。

13.1.2 Stage 2: 随机变量

用指示变量

$$X_i = \mathbf{1}_{A_i}$$

把事件编码成 0/1 数值。

13.1.3 Stage 3: 分布与和

$X_i \sim \text{Bernoulli}(p)$, 独立重复后

$$S_n = \sum X_i \sim B(n, p).$$

13.1.4 Stage 4: 数字特征

$$E(S_n) = np, \quad \text{Var}(S_n) = np(1-p).$$

13.1.5 Stage 5: 样本比例

$$\bar{X} = \frac{S_n}{n}, \quad E\bar{X} = p, \quad \text{Var}(\bar{X}) = \frac{p(1-p)}{n}.$$

13.1.6 Stage 6: LLN 与 CLT 极限导出

LLN: 当 $n \rightarrow \infty$ 时, $\text{Var}(\bar{X}_n) = \frac{p(1-p)}{n} \rightarrow 0 \implies \bar{X}_n \xrightarrow{P} p$ (切比雪夫大数定律, 频率依概率收敛于概率);

CLT：由 De Moivre–Laplace 中心极限定理，标准化残差：

$$Z_n = \frac{\bar{X}_n - p}{\sqrt{p(1-p)/n}} \xrightarrow{d} N(0, 1).$$

13.1.7 Stage 7: 统计逆推与估计

若 p 未知，由样本 $x_1, \dots, x_n$ (含有 k 次成功)，极大似然函数 $L(p) = \binom{n}{k} p^k (1-p)^{n-k}$ 。求导 $\frac{d \ln L}{dp} = 0 \implies \hat{p} = \frac{k}{n} = \bar{x}$ (MLE 点估计)。并由大样本正态近似导出 p 的 $1-\alpha$ 置信区间 $\left(\bar{x} - z_{\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}}, \bar{x} + z_{\alpha/2} \sqrt{\frac{\bar{x}(1-\bar{x})}{n}} \right)$ 。

13.2 正态总体：从模型结构到 N, χ^2, t, F 和推断全过程推演

13.2.1 Stage 1: 总体模型与独立抽样

$$X_1, \dots, X_n \stackrel{iid}{\sim} N(\mu, \sigma^2).$$

13.2.2 Stage 2: 样本均值与样本方差的推导

样本均值 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i \sim N\left(\mu, \frac{\sigma^2}{n}\right) \implies Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$;

样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 。由正态性质， $\bar{X}$ 与 S^2 相互独立，且离差平方和满足：

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \left(\frac{X_i - \bar{X}}{\sigma} \right)^2 \sim \chi^2(n-1).$$

13.2.3 Stage 3: 抽样分布 t 统计量的完整导出

当总体方差 σ^2 未知时，用样本标准差 S 替代 σ 。构造标准正态与独立 χ^2 均方根的比值：

$$t = \frac{Z}{\sqrt{\frac{(n-1)S^2/\sigma^2}{n-1}}} = \frac{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}}}{\frac{S}{\sigma}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

13.2.4 Stage 4: 区间估计推导

由 $P\left(-t_{\alpha/2}(n-1) \leq \frac{\bar{X} - \mu}{S/\sqrt{n}} \leq t_{\alpha/2}(n-1)\right) = 1 - \alpha$ ，解不等式可得未知均值 μ 的双侧 $1-\alpha$ 置信区间为：

$$\left[\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right].$$

13.2.5 Stage 5: 假设检验反证决策推演

假设 $H_0: \mu = \mu_0$ (σ 未知)。在 H_0 为真世界里，检验统计量 $T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1)$ 。显著性水平 α 下拒绝域为 $W = \{|T| \geq t_{\alpha/2}(n-1)\}$ 。若观测值 t_{obs} 进入拒绝域，说明看到了小概率发生的极端数据，故拒绝 H_0 ！

两个母例分别承担什么

Bernoulli 母例负责展示事件如何被数值化、独立重复如何产生计数、频率为何稳定、CLT 如何近似、样本比例如何估计参数；正态母例负责展示统计量为什么有抽样分布、为什么会出现 χ^2, t, F 、区间估计与检验为什么共享同一套标尺。两者合起来基本覆盖整门概率统计的骨架。

数学一概率论与数理统计完整覆盖清单

覆盖原则

正文按心智模型组织，不按考纲目录逐条展开；本附录负责防漏。范围校验参考公开转载的 2026 数学（一）考试大纲，正式备考以报考年度官方考试大纲为最终边界。

一、随机事件和概率

- 随机事件与样本空间；事件关系与运算；
- 概率基本性质；古典概型；几何概型；
- 条件概率；概率加法、减法、乘法公式；
- 全概率公式；Bayes 公式；
- 事件独立性；独立重复试验。

二、随机变量及其分布

- 随机变量；分布函数；离散型随机变量分布律；连续型随机变量概率密度；
- 0-1、Binomial、Geometric、Hypergeometric、Poisson；
- Poisson 近似 Binomial；
- Uniform、Normal、Exponential；
- 随机变量函数的分布。

三、多维随机变量及其分布

- 多维随机变量；联合分布函数；联合分布律/密度；
- 边缘分布；条件分布；
- 随机变量相互独立；不相关；
- 二维均匀分布、二维正态分布的基本结构；

- 两个及多个随机变量简单函数的分布，包括和等典型变换。

四、数字特征

- 数学期望、方差、标准差；
- 随机变量函数的数学期望；
- 矩；协方差；相关系数及性质；
- 常见分布的期望与方差；
- Chebyshev 不等式。

五、大数定律和中心极限定理

- Chebyshev 大数定律；Bernoulli 大数定律；Khinchin 大数定律；
- De Moivre–Laplace 中心极限定理；
- Levy–Lindeberg iid 中心极限定理。

六、数理统计基本概念

- 总体、个体、简单随机样本、统计量；
- 样本均值、样本方差、样本矩；
- χ^2 、 t 、 F 分布及基本性质；
- 上侧分位数；
- 正态总体常用抽样分布。

七、参数估计

- 点估计、估计量与估计值；
- 矩估计法（一阶矩、二阶矩）；
- 最大似然估计法；
- 无偏性、有效性、一致性；无偏性验证；
- 区间估计；
- 单个正态总体均值和方差的置信区间；
- 两个正态总体均值差和方差比的置信区间。

八、假设检验

- 显著性检验基本思想；
- 假设检验基本步骤；
- 第一类和第二类错误；
- 单个及两个正态总体均值的假设检验；
- 单个及两个正态总体方差相关假设检验。

当前范围核验来源

公开范围核验参考：<https://kaoyan.wendu.com/m/2025/1017/212673.shtml>。该页面列出数学一概率统计的八个模块及要求；本册没有把高校自命题概率统计课程中的回归、方差分析、充分统计量等内容混入数学一主线。

一页压缩：概率统计最终应该留下什么

第一层：一句话

概率论把随机机制变成可计算的分布；数理统计利用统计量的抽样分布，把有限数据变成关于未知机制的可控推断。

第二层：对象链

$$\Omega \rightarrow \text{Event} \rightarrow X \rightarrow \text{Distribution} \rightarrow \text{Joint/Conditional}$$

$$E/\text{Var} \rightarrow \text{Sample} \rightarrow \text{Statistic} \rightarrow \text{Inference}$$

看到任何新概念，先判断它位于哪一层。

第三层：三种基本信息操作

- **Condition**：加入信息，缩小随机世界并重新归一化；
- **Marginalize**：忽略一个维度，把所有概率贡献加总；
- **Transform**：换观察函数，重新搬运概率质量。

第四层：大量重复与统计桥

$$\text{LLN: stability} \quad \text{CLT: fluctuation shape}$$

LLN 解释估计为什么可能稳定，CLT/抽样分布解释估计误差如何量化。

第五层：统计决策

$$\text{Unknown parameter} \rightarrow \text{Statistic} \rightarrow \text{Sampling distribution} \rightarrow \text{Estimate / Interval / Test.}$$

任何统计题都先找“哪个统计量的概率分布能把数据和未知参数连接起来”。