

秩、基本子空间与等价

一份输入自由度，怎样分成“留下的”和“被抹掉的”

数学一 · 线性代数 Topic 03

母问题：一个线性作用到底保留了多少独立自由度，又把多少自由度压掉了？

给一个矩阵 A ，只说“它有多少个非零元素”几乎没有结构意义。真正重要的是：输入空间中有多少彼此独立的方向能够在输出端留下可区分的信息，又有多少方向被映射完全抹掉。

因此本册的母模型不是“rank 有几种算法”，而是

$$\text{输入自由度} = \text{被抹除的自由度} + \text{留下可见输出的自由度}$$

在线性映射 $T: V \rightarrow W$ 上，这句话精确写成

$$\dim V = \dim \ker T + \dim \operatorname{Im} T.$$

其中

$$\operatorname{rank} T = \dim \operatorname{Im} T, \quad \operatorname{nullity} T = \dim \ker T.$$

1 本册负责什么

- **Owens**: rank、kernel/image 的自由度机制、rank-nullity、行秩 = 列秩、主元/最大非零子式等 rank 观测方式、矩阵等价、rank 运算规律、乘积的中间瓶颈、低秩结构、伴随矩阵的 rank 分层。
- **Uses**: Topic 01 的 span/基/维数/正交；Topic 02 的线性映射、两端换基、初等矩阵、determinant 与 adjugate 恒等式。
- **Does not own**: 给定 b 的相容性与完整解集；相似和特征结构；二次型惯性。

Topic 04 会直接调用本册提供的两个输出：

$$b \in \operatorname{Im} A? \quad \dim \ker A = n - r(A).$$

但“某个具体 b 是否可达，以及所有逆像怎样写”属于 Topic 04。

2 先认两个主角：Kernel 与 Image

设

$$A \in \mathbb{R}^{m \times n}, \quad A: \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

Kernel / 零空间是

$$\ker A = \{x \in \mathbb{R}^n : Ax = 0\}.$$

它记录所有被作用完全压成零的输入方向。

Image / 像空间是

$$\operatorname{Im} A = \{Ax : x \in \mathbb{R}^n\}.$$

若把 A 的列写成 $a_1, \dots, a_n$, 则

$$Ax = x_1 a_1 + \dots + x_n a_n,$$

所以

$$\boxed{\operatorname{Im} A = \operatorname{Col}(A).}$$

于是矩阵的秩可以直接定义为

$$\boxed{r(A) = \dim \operatorname{Im} A = \dim \operatorname{Col}(A).}$$

它不是“非零元素个数”，而是输出端真正能够留下的独立方向数。

母例 1：二维输入被压成一维

取

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}.$$

所有输出都形如

$$Ax = (x_1 + x_2) \begin{pmatrix} 1 \\ 1 \end{pmatrix},$$

所以

$$\operatorname{Im} A = \operatorname{span} \left\{ \begin{pmatrix} 1 \\ 1 \end{pmatrix} \right\}, \quad r(A) = 1.$$

同时

$$Ax = 0 \iff x_1 + x_2 = 0,$$

故

$$\ker A = \operatorname{span} \left\{ \begin{pmatrix} 1 \\ -1 \end{pmatrix} \right\}.$$

二维输入里，一个自由方向留下可见输出，一个自由方向被压掉：

$$\boxed{2 = 1 + 1.}$$

3 Rank–Nullity 为什么必然成立

不要把

$$n = r(A) + \dim \ker A$$

当成一个需要背的维数公式。它可以直接从“给 kernel 选基，再把它扩充成整个输入空间的基”推出。

设

$$k_1, \dots, k_s$$

是 $\ker T$ 的一组基。把它扩充为 V 的一组基：

$$k_1, \dots, k_s, v_1, \dots, v_r.$$

于是

$$\dim V = s + r.$$

现在看 $T(v_1), \dots, T(v_r)$ 。

3.1 它们生成整个 Image

任意 $x \in V$ 可写成

$$x = \sum_{j=1}^s b_j k_j + \sum_{i=1}^r a_i v_i.$$

作用 T 后，kernel 部分全部消失：

$$T(x) = \sum_{i=1}^r a_i T(v_i).$$

所以 $T(v_1), \dots, T(v_r)$ 生成 $\text{Im } T$ 。

3.2 它们还线性无关

若

$$\sum_{i=1}^r a_i T(v_i) = 0,$$

则

$$T\left(\sum_{i=1}^r a_i v_i\right) = 0,$$

所以 $\sum a_i v_i \in \ker T$ 。但

$$k_1, \dots, k_s, v_1, \dots, v_r$$

是一组基，表示唯一；一个只含 v_i 的组合若又落在由 k_j 张成的 kernel 中，只能所有 $a_i = 0$ 。

因此 $T(v_1), \dots, T(v_r)$ 是 $\text{Im } T$ 的一组基，故

$$\dim \text{Im } T = r.$$

最终得到

$$\boxed{\dim V = \dim \ker T + \dim \text{Im } T.}$$

Rank-Nullity 的真正含义

它不是说每根输入基向量单独“选择留下或消失”。真正的结构是：可以选择一组适合 kernel 的输入基，使一部分基方向正好张成 kernel，其余方向的像恰好成为 image 的基。

因此“被抹除自由度 + 可见自由度 = 输入自由度”是一份可以通过选基显式看见的分解。

4 同一个 rank 为什么会有这么多观测方式

对 $A \in \mathbb{R}^{m \times n}$, 下面这些数字最终都相同:

观测方式	它在看什么
列向量组的极大无关组个数	输出端能生成多少独立方向
$\dim \text{Col}(A)$	image 的维数
$\dim \text{Row}(A)$	独立行约束 / 输入线性函数有多少独立方向
阶梯形中的主元个数	消元后剩下多少独立结构
最大非零子式的阶数	最大能截出多大的可逆方块
线性映射的 rank	作用后保留下来的自由度

这些不是六个互相独立的定义, 而是同一份“独立信息维数”在向量、空间、消元、determinant 和映射语言中的不同投影。

5 为什么行秩等于列秩

对矩阵做可逆行变换。Topic 02 已说明: 左乘可逆矩阵不会改变列之间的线性关系, 因此列 rank 不变; 同时新旧行互为可逆线性组合, 所以行空间维数也不变。

把 A 化为行阶梯形 R 。若 R 有 r 个非零行, 则:

- 非零行的首非零位置逐级右移, 因此这 r 行线性无关, 行 rank 为 r ;
- 恰有 r 个主元列, 主元列线性无关, 其余列由它们生成, 因此列 rank 也为 r 。

于是

$$\dim \text{Row}(A) = \dim \text{Col}(A) = r(A).$$

行空间和列空间不是同一个集合

它们只有维数相等。若 A 是 $m \times n$ 非方阵,

$$\text{Row}(A) \subseteq \mathbb{R}^n, \quad \text{Col}(A) \subseteq \mathbb{R}^m,$$

甚至生活在不同环境空间里, 不能写成“行空间 = 列空间”。

6 最大非零子式与主元: 为什么它们也能测 rank

一个 r 阶子式非零, 表示从 A 中选出的 r 行、 r 列组成一个可逆方阵, 因此至少存在 r 个独立方向:

$$r(A) \geq r.$$

如果所有 $(r+1)$ 阶子式都为零, 就不可能再截出一个 $(r+1)$ 维可逆作用, 因此

$$r(A) \leq r.$$

所以

$$r(A) = r \iff \begin{cases} \text{至少一个 } r \text{ 阶子式非零,} \\ \text{所有 } (r+1) \text{ 阶子式为零.} \end{cases}$$

这也是 determinant 与 rank 的责任分界: 对 $n \times n$ 方阵, $\det A \neq 0$ 只说明 $r(A) = n$; 若 $\det A = 0$, 具体是 $n-1$ 还是更低, 必须继续由 rank 判断。

7 矩阵等价: 把 kernel 与 image 都换到最干净的坐标

Rank-Nullity 的基扩充证明还能继续生成一件更强的事。

对 $T: V_n \rightarrow W_m$, 沿用 Rank-Nullity 中得到的两组方向, 但为了让标准形的单位块出现在左上角, 把输入基重新排序为

$$v_1, \dots, v_r, k_1, \dots, k_{n-r},$$

其中 k_j 张成 kernel, 而 $T(v_1), \dots, T(v_r)$ 是 image 的一组基。再在输出端把

$$T(v_1), \dots, T(v_r)$$

扩充成 W 的一组基。

在这两组“适配映射结构”的基下, 前 r 个输入基向量依次送到前 r 个输出基向量, 后 $n-r$ 个 kernel 基向量全部送到零, 因此 T 的矩阵直接变成

$$J_r = \begin{pmatrix} I_r & 0 \\ 0 & 0 \end{pmatrix}_{m \times n}.$$

这张矩阵把映射的全部本质压缩成一句话: 前 r 个输入方向被无损保留, 其余 $n-r$ 个输入方向被压成零。

一般矩阵等价写成

$$B = PAQ,$$

其中 P, Q 可逆。它允许输入端和输出端独立重编码, 因此

$$A \sim_{\text{eq}} B \iff r(A) = r(B)$$

(同型矩阵)。

原因已经不是“初等变换碰巧保持 rank”, 而是: 每个 rank 为 r 的映射都能选基化成同一个 J_r 。

同 rank 只保证等价, 不保证相似

矩阵等价允许两端独立换基; 相似要求同一空间算子在输入/输出端同步换同一组基。因此

$$\text{同 rank} \implies \text{等价},$$

但一般不能推出相似。

例如 I_2 与 $\text{diag}(1, 2)$ 都 rank 2，因此等价；但特征值不同，所以不相似。

8 初等变换到底保护哪些子空间

设 P, Q 可逆。

变换	稳定的东西	会怎样移动
$A \mapsto PA$	rank、列间线性关系、 row space	$\text{Col}(PA) = P \text{Col}(A)$ ，具体输出方向会移动
$A \mapsto AQ$	rank、column space	$\ker(AQ) = Q^{-1} \ker A$ ，row space 在输入坐标中被 Q 重编码
$A \mapsto PAQ$	rank	输入/输出两侧的具体方向都可以变，只保留自由度数量

因此“初等变换保持什么”必须带对象：**rank** 始终保持；具体子空间的位置未必保持。

9 四个基本子空间：主干只有一对，另外两个是正交镜像

在标准内积下，矩阵还自然带出 row space 与 $N(A^T)$ ：

$$\text{Row}(A) = \text{Col}(A^T).$$

对任意 x ， $Ax = 0$ 等价于 x 与 A 的每一行都正交，因此

$$\ker A = \text{Row}(A)^\perp.$$

同理

$$\ker A^T = \text{Col}(A)^\perp.$$

于是

$$\mathbb{R}^n = \text{Row}(A) \oplus \ker A,$$

$$\mathbb{R}^m = \text{Col}(A) \oplus \ker A^T.$$

数学一里怎样给这四个空间排优先级？

真正反复生成题目的是

$$\ker A \quad \text{和} \quad \text{Im } A = \text{Col}(A).$$

row space 主要用于解释行秩、独立约束和齐次同解； $\ker A^T$ 主要解释“输出空间中与所有可达方向正交的部分”。

所以不要把“四大基本子空间”再学成四份并列名词表。它们是 kernel/image 主模型在标准内积下的两组正交镜像。

10 Rank-one: 最小的非零信息通道

令

$$A = uv^T, \quad u \neq 0, v \neq 0.$$

则

$$Ax = u(v^T x).$$

输入 x 先被压缩成一个标量 $v^T x$, 再沿 u 方向输出。因此

$$\text{Im } A = \text{span}\{u\}, \quad r(A) = 1,$$

而

$$\ker A = \{x : v^T x = 0\} = v^\perp.$$

这给“低秩”的最小直觉：低秩不是元素少，而是作用只通过少量独立标量通道传递信息。

若进一步是方阵 $A = uv^T \in \mathbb{R}^{n \times n}$, 记

$$g = v^T u = \text{tr } A.$$

那么外积可以直接闭合：

$$A^2 = uv^T uv^T = (v^T u)uv^T = gA,$$

因此

$$A^1 = A, \quad \boxed{A^k = g^{k-1} A \quad (k \geq 2).}$$

这样写可以避免 $g = 0$ 、 $k = 1$ 时出现 0^0 的形式歧义；真正的结构结论仍是：从二次幂开始，所有高次幂都压回同一条 rank-one 通道。

方阵 rank-one 的迹为什么是谱接口？

因为 $Au = gu$, 所以 g 是一个特征值；而

$$\ker A = v^\perp$$

维数为 $n - 1$, 因此 0 至少提供 $n - 1$ 个独立特征方向。

于是：

- 若 $g \neq 0$, $\mathbb{R}^n = \text{span}\{u\} \oplus \ker A$, A 可对角化, 谱为 $g, 0, \dots, 0$;
- 若 $g = 0$ 且 $A \neq 0$, 则 $A^2 = 0$, 全部特征值都是 0 , 但 $\ker A$ 只有 $n - 1$ 维, 所以不可对角化。

完整“多项式关系为什么控制可对角化”的机制由 Topic 05 接管；这里把 rank-one 作为跨册母例输出。

怎样从数表识别 rank one?

对非零矩阵, 下列信号都在表达同一件事：所有输出只剩一条独立方向。

- 所有非零列彼此成比例；
- 所有非零行彼此成比例；
- 可以直接写成外积 uv^T ；

- 所有 2×2 子式都为 0。

最后一条只能先推出 $r(A) \leq 1$ ，还必须排除 $A = 0$ 才能断言 $r(A) = 1$ 。

Extension: 奇异值分解 (SVD) 的高级镜头

Rank-one 矩阵的外积结构 $A = uv^T$ 实际上是所有矩阵最底层的“乐高积木”。根据奇异值分解 (SVD) 定理，任何矩阵都可以写成一系列 rank-one 矩阵的加权和：

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T.$$

这里 σ_i 是非零奇异值， u_i 和 v_i 分别是输出空间和输入空间的一组标准正交基。这给出了 rank 的终极统一视角：矩阵的 rank 恰好等于其非零奇异值的个数，而每一个 rank-one 分量都代表着一个独立的信息传输通道。

11 乘积的 rank：真正的瓶颈是 $\text{Im } B$ 撞上 $\ker A$

设

$$B: \mathbb{R}^p \rightarrow \mathbb{R}^n, \quad A: \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

复合为 AB 。先由 B 把输入送进 $\text{Im } B$ ，再由 A 作用。真正会在第二段继续消失的，是

$$\text{Im } B \cap \ker A.$$

把 A 限制在 $\text{Im } B$ 上，对这个限制映射使用 rank-nullity：

$$r(AB) = r(B) - \dim(\text{Im } B \cap \ker A).$$

这条式子一次生成所有常用边界。

11.1 上界

显然

$$r(AB) \leq r(B).$$

同时 AB 的 image 位于 A 的 image 中，所以

$$r(AB) \leq r(A).$$

故

$$r(AB) \leq \min\{r(A), r(B)\}.$$

11.2 Sylvester 下界

中间空间维数为 n ，而

$$\dim \ker A = n - r(A).$$

所以

$$\dim(\text{Im } B \cap \ker A) \leq n - r(A),$$

从而

$$r(AB) \geq r(A) + r(B) - n.$$

11.3 什么时候上下界真正取到?

主公式

$$r(AB) = r(B) - \dim(\text{Im } B \cap \ker A)$$

不仅给范围，也直接给取等条件。

若希望第二段作用完全不再丢方向，即

$$r(AB) = r(B),$$

必须且只需

$$\text{Im } B \cap \ker A = \{0\}.$$

若希望 Sylvester 下界取等，交集必须达到它可能的最大维数 $\dim \ker A = n - r(A)$ ，即

$$\ker A \subseteq \text{Im } B.$$

此时 B 已经产生了 A 所有会抹掉的方向，第二段把这部分自由度全部损失掉。

另一侧若已知 $r(A) \leq r(B)$ ，上界 $r(AB) = r(A)$ 等价于 A 在 $\text{Im } B$ 上已经能产生自己的全部 image；可写成

$$\text{Im } B + \ker A = \mathbb{R}^n.$$

这些条件都比“记住何时取等”更稳定，因为它们只是同一个交集公式的不同边界情形。

11.4 Frobenius 不等式

复合结构还能生成更一般的三矩阵乘积下界。对于复合 ABC ，有：

$$r(ABC) \geq r(AB) + r(BC) - r(B).$$

Sylvester 不等式其实是令 $B = I_n$ 时的特殊情况。只要盯住“前面保留的图像，有多少继续被后面的核空间吃掉”，所有秩不等式都能从子空间交集的维数中读出。

11.5 $AB = 0$ 为什么能直接变成 rank 约束

$$AB = 0 \iff \text{Im } B \subseteq \ker A.$$

因此

$$r(B) \leq n - r(A),$$

即

$$r(A) + r(B) \leq n.$$

不要背 $r(AB)$ 的一堆孤立公式

先写

$$\text{Im } B \xrightarrow{A} \text{Im}(AB)$$

再问： B 已经产生的方向中，有多少正好落入 $\ker A$ ？所有乘积 rank 结论都围绕这个交集展开。

12 和、转置与 Gram 型矩阵的 rank

若 A, B 同型，则每个 $(A+B)x$ 都属于

$$\text{Im } A + \text{Im } B,$$

因此

$$r(A+B) \leq r(A) + r(B).$$

这只是上界；两个 image 大量重叠或相互抵消时，实际 rank 可以更小。

由行秩 = 列秩，

$$r(A^T) = r(A).$$

在实数域，

$$\ker(A^T A) = \ker A.$$

因为

$$A^T A x = 0 \implies x^T A^T A x = \|Ax\|^2 = 0 \implies Ax = 0,$$

反向显然成立。两者列数相同，所以 rank-nullity 给出

$$r(A^T A) = r(A).$$

同理

$$r(AA^T) = r(A).$$

而且 $A^T A$ 不只是“与 A 同 rank”。对任意 x ，

$$x^T A^T A x = \|Ax\|^2 \geq 0,$$

所以它天然就是半正定矩阵；进一步

$$A^T A \succ 0 \iff \ker A = \{0\} \iff r(A) = n$$

(这里 A 有 n 列)。也就是说， $A^T A$ 正定恰好表示 A 的输入端没有任何方向被压掉。正定性的完整分类仍由 Topic 06 拥有，本册只提供这个由 kernel 直接生成的接口。

这类结论不是“转置以后 rank 神秘保持”，而是 kernel / image 结构没有产生新的自由度损失。

13 伴随矩阵的 rank: Topic 02 的恒等式怎样在这里继续生长

Topic 02 已有

$$A \operatorname{adj}(A) = (\det A)I.$$

对 $n \times n$ 矩阵 ($n \geq 2$), rank 分三层:

$$r(\operatorname{adj} A) = \begin{cases} n, & r(A) = n, \\ 1, & r(A) = n - 1, \\ 0, & r(A) \leq n - 2. \end{cases}$$

- 若 $r(A) = n$, 则 $\det A \neq 0$, 且

$$\operatorname{adj}(A) = (\det A)A^{-1},$$

所以满秩;

- 若 $r(A) \leq n - 2$, 所有 $(n - 1)$ 阶子式都为 0, 所以每个 cofactor 都为 0, 即 $\operatorname{adj}(A) = 0$;
- 若 $r(A) = n - 1$, 至少一个 $(n - 1)$ 阶子式非零, 所以 adjugate 非零; 又因 $\det A = 0$,

$$A \operatorname{adj}(A) = 0,$$

adjugate 每一列都落入一维的 $\ker A$, 故 rank 至多 1。非零再迫使 rank 恰为 1。

14 含参数 rank: 为什么只需要盯住结构跳变点

rank 是整数, 不会随着参数连续地“慢慢变化”。它改变的时刻, 必然有某个原本非零的关键主元或子式变成零。

例如

$$A(a) = \begin{pmatrix} 1 & a \\ a & 1 \end{pmatrix}.$$

其 determinant 为

$$1 - a^2.$$

所以

$$r(A) = 2 \quad (a \neq \pm 1),$$

而当 $a = \pm 1$ 时 determinant 归零, 但矩阵并非零矩阵, 因此

$$r(A) = 1.$$

这说明含参数 rank 的核心不是“每个参数值重新算一遍”, 而是: 找出哪些参数让当前独立结构失效。

具体消元时, 不能未经分类就除以可能为零的参数因子。路线优先级属于 Rules; 本册只负责解释为什么要分支。


15 概念边界：rank 最容易被什么伪装

A ≠ B	为什么容易混	真正判据	题面信号	混淆后果
rank ≠ 非零元素个数	都像在“计数量”	rank 只计独立方向	稀疏/满元素矩阵	用元素多少误判自由度
rank ≠ 非零行数	阶梯形里两者恰好相同	只有化到阶梯形后非零行才自动无关	消元、主元	未消元就数行
行空间 ≠ 列空间	行秩 = 列秩	相等的是维数，不是集合	非方阵、转置	把不同环境空间写成同一集合
行变换保 rank ≠ 保列空间	都涉及左乘可逆矩阵	$\text{Col}(PA) = P \text{Col}(A)$	行初等变换	错把输出方向当作不变
同 rank ≠ 相似	两者都是矩阵关系	同 rank 完全分类“等价”，相似还保谱	PAQ vs $P^{-1}AP$	用 rank 判断算子相似
$\det A = 0 \neq$ rank 已知	determinant 也测退化	$\det$ 只告诉方阵 rank $< n$	奇异方阵	把 $n - 1$ 与更低 rank 混为一谈
$r(AB) \neq r(A)r(B)$	标量乘法直觉	看 $\text{Im } B \cap \ker A$	矩阵乘积、 $AB = 0$	背错误乘法公式
$AB = 0 \neq A = 0$ 或 $B = 0$	数域没有零因子	只需 $\text{Im } B \subseteq \ker A$	零乘积	错过非零矩阵乘积为零

16 看到什么信号时调用本册模型

- 看到“秩、极大无关组、主元、最大非零子式”：统一翻译成“独立信息有几维”；
- 看到齐次方程自由变量个数：先回到 $n - r(A) = \dim \ker A$ ，完整解集转 Topic 04；
- 看到两个矩阵做行列初等变换：若目标是分类，问它们是否只在独立重编码输入/输出，从而进入矩阵等价；
- 看到 AB ：先画 $\text{Im } B$ 与 $\ker A$ ，不要先猜 rank 公式；
- 看到 $AB = 0$ ：立即翻译为 $\text{Im } B \subseteq \ker A$ ；
- 看到 $A^T A$ 、 AA^T ：优先比较 kernel，而不是展开元素；
- 看到 adjugate 与 rank：先按 $r(A) = n, n - 1, \leq n - 2$ 分层；
- 看到含参数 rank：先定位主元/非零子式何时失效，再分支。

17 一页压缩：rank 是一份“自由度账本”



最终压成四句话：

$$r(A) = \dim \operatorname{Im} A.$$

$$n = r(A) + \dim \ker A.$$

$$A \sim_{\text{eq}} B \iff r(A) = r(B) \quad (\text{同型矩阵}).$$

$$r(AB) = r(B) - \dim(\operatorname{Im} B \cap \ker A).$$

如果忘掉具体公式，重新问：输入有多少自由度？哪些方向被压没？哪些方向还能被输出看见？复合时中间 image 有多少撞进下一步 kernel？