

# 总体、样本与抽样分布

统计量为什么仍然随机？正态总体下的四大抽样标尺

数学一 · 概率统计 Topic 07

母问题：统计量为什么仍然随机？正态总体下的四大抽样标尺

看到数据以后容易忘记它原本会变化。简单随机样本  $X_1, \dots, X_n$  是总体分布的独立同分布副本；统计量是样本的函数。正态总体下，样本均值与样本方差拥有特殊的独立性与三大精确抽样分布 ( $\chi^2, t, F$ )。这里先约定：i.i.d. 表示“相互独立且同分布”，只压缩这两个条件。

主线推演逻辑：

$$\begin{array}{c} \text{总体 } X \xrightarrow{\text{i.i.d. 抽样}} \text{样本 } (X_1, \dots, X_n) \xrightarrow{\text{信息压缩}} \text{统计量 } \bar{X}, S^2 \\ \xrightarrow{\text{正态精确推导}} \chi^2(n-1) \text{ 与 } t(n-1) \text{ 与 } F(m, n) \end{array}$$

## 1 本册定位与职责划分

- **本册拥有 (Owns)**：总体、简单随机样本 (i.i.d.)、统计量、样本均值  $\bar{X}$ 、样本方差  $S^2$ 、样本矩、三大抽样分布 ( $\chi^2$  分布、 $t$  分布、 $F$  分布)、正态总体的抽样分布定理 (Fisher 定理)。
- **本册使用 (Uses)**：二维分布与数字特征。
- **本册不拥有 (Does not own)**：点估计构造与区间/检验反演 (Topic 08 负责)。
- **输出目标 (Output)**：统计量的精确分布律与临界分位数标尺。

## 2 第一层：总体、样本与二重性

总体不是“所有可能取值的集合”，而是带有概率规律的模型  $X \sim F(x; \theta)$ ； $\theta$  是固定但未知的参数。容量为  $n$  的简单随机样本要求同分布与相互独立：

$$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} F(x; \theta).$$

连续总体的联合密度、离散总体的联合质量分别为

$$f_{\mathbf{X}}(x_1, \dots, x_n; \theta) = \prod_{i=1}^n f(x_i; \theta), \quad P_{\theta}(\mathbf{X} = \mathbf{x}) = \prod_{i=1}^n p(x_i; \theta).$$

抽样前  $\mathbf{X}$  与  $T(\mathbf{X})$  是随机对象；抽样后  $\mathbf{x}$  与  $T(\mathbf{x})$  是确定观测值。统计量是只含样本、不含未知参数的可测函数；其抽样分布仍然可以依赖  $\theta$ 。只有当该统计量被用于估计某个参数时，才称为估计量。

有限总体不放回抽样通常引入相关性，不应默认 i.i.d.；只有有放回抽样、独立重复观测或明确的超总体模型才能直接使用乘积联合分布。

### 3 第二层：样本数字特征与平方和分解

记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k,$$

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

若总体均值和方差为  $\mu, \sigma^2$ , 则

$$E(\bar{X}) = \mu, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad E(S^2) = \sigma^2,$$

而  $E(B_2) = (n-1)\sigma^2/n$ 。  $S^2$  无偏不代表  $S$  对  $\sigma$  无偏, 因为平方根是非线性变换。


核心恒等式为

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n X_i^2 - n\bar{X}^2,$$

以及围绕真实均值的分解

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n (X_i - \bar{X})^2 + n(\bar{X} - \mu)^2.$$

第二式的交叉项消失源于  $\sum_i (X_i - \bar{X}) = 0$ 。离差向量因此落在一个  $n-1$  维子空间, 解释了  $S^2$  的分母与卡方自由度。



#### 1. 正交分解与勾股定理 (平方和恒等式)

- 样本向量沿全 1 方向做正交投影:  $\mathbf{X} = \bar{X}\mathbf{1} + \mathbf{e}$
- 正交性保证交叉项为零:  $\sum_{i=1}^n e_i = \sum_{i=1}^n (X_i - \bar{X}) = 0$
- 勾股定理对应平方和分解:
 
$$\underbrace{\sum_{i=1}^n (X_i - \mu)^2}_{\|\mathbf{X} - \mu\mathbf{1}\|^2} = \underbrace{n(\bar{X} - \mu)^2}_{\|\bar{X}\mathbf{1} - \mu\mathbf{1}\|^2} + \underbrace{\sum_{i=1}^n (X_i - \bar{X})^2}_{\|\mathbf{e}\|^2 = (n-1)S^2}$$

#### 2. 自由度账本与独立性本质

- 自由度本质: 残差受约束  $\sum e_i = 0$ , 波动维数为  $n-1$
- 正态旋转对称性: 正态随机向量在正交基下投影相互独立
- 统计量精确分布律:

几何本质: 均值占用 1 个位置方向 (自由度 1), 残差在正交的  $n-1$  维子空间中自由波动; 正态旋转对称性保证二者严格概率独立。

图 7.1 样本向量正交分解与自由度几何 (V15): 均值方向与残差超平面的正交独立性

### 中心化残差的几何约束与协方差

令  $Y_i = X_i - \bar{X}$ 。中心化不是逐个独立变换：恒等式

$$\sum_{i=1}^n Y_i = 0$$

给出一个确定的线性约束，因此残差向量只在维数  $n-1$  的子空间内波动。若  $X_i$  i.i.d. 且  $\text{Var}(X_i) = \sigma^2$ ，则

$$\text{Var}(Y_i) = \sigma^2 \left(1 - \frac{1}{n}\right), \quad \text{Cov}(Y_i, Y_j) = -\frac{\sigma^2}{n} \quad (i \neq j).$$

第二式也可由对固定  $i$  的关系  $0 = \text{Cov}(Y_i, \sum_j Y_j)$  推出。正态性只保证  $\bar{X}$  与整个残差向量（或残差子空间的正交投影）独立，不保证不同  $Y_i$  之间独立；这正是“残差自由度为  $n-1$ ”的协方差版本。

若  $E(X^4) < \infty$ ，样本方差的一般方差为

$$\text{Var}(S^2) = \frac{1}{n} \left( \mu_4 - \frac{n-3}{n-1} \sigma^4 \right),$$

其中  $\mu_4 = E[(X - \mu)^4]$ 。正态总体下  $\mu_4 = 3\sigma^4$ ，于是  $\text{Var}(S^2) = 2\sigma^4/(n-1)$ ；四阶矩条件不能省略。

## 4 第三层：顺序统计量；经验分布作为拓展接口

将样本排列为  $X_{(1)} \leq \dots \leq X_{(n)}$ 。最大值、最小值的 CDF 为

$$F_{X_{(n)}}(x) = [F(x)]^n, \quad F_{X_{(1)}}(x) = 1 - [1 - F(x)]^n.$$

第  $k$  个顺序统计量满足

$$F_{X_{(k)}}(x) = \sum_{j=k}^n \binom{n}{j} F(x)^j [1 - F(x)]^{n-j}.$$

若总体连续且有密度  $f$ ，则

$$f_{X_{(k)}}(x) = \frac{n!}{(k-1)!(n-k)!} F(x)^{k-1} [1 - F(x)]^{n-k} f(x).$$

### 顺序统计量密度的计算骨架

事件  $X_{(k)} \leq x$  等价于“至少  $k$  个样本不超过  $x$ ”，因此 CDF 是参数为  $F(x)$  的二项尾和。对连续总体求导时，恰好有  $k-1$  个样本落在  $(-\infty, x)$ 、一个样本落在  $[x, x+dx)$ 、其余落在  $(x, \infty)$ ；乘上三段概率和排列数，再除以  $dx$ ，得到上式。连续性是这里把“邻域内一个”转成密度的前提；有原子时必须回到 CDF 或离散计数。

### 离散顺序统计量：回到 CDF 与原子计数

离散总体没有连续密度可供“在  $x$  附近取一个”求导。对最大值仍直接使用

$$P(X_{(n)} \leq x) = F(x)^n,$$

再由相邻 CDF 值取原子质量：

$$P(X_{(n)} = x) = F(x)^n - F(x^-)^n.$$

对联合最大值/最小值, 先写支持  $y \leq x$ ; 若  $x = y$ , 所有样本落在该点的路径只有相等路径, 若  $x > y$ , 要把不同排列路径相加。不要把连续顺序统计量密度公式中的  $f(x)$  直接替换成 PMF; 离散问题的基本单位是原子质量与排列计数。

连续 CDF 变换给出  $F(X_{(k)}) \sim \text{Beta}(k, n - k + 1)$ ; 均匀总体时  $X_{(k)}$  本身即为该 Beta 分布。密度公式的机制是“左边  $k - 1$  个、邻域内一个、右边  $n - k$  个”再乘排列数, 不能误解为连续变量在单点有正概率。

#### 数学一范围边界: 经验分布保留为拓展, 不挤占主干

本套旧九章资料已明确把“经验分布函数”标为偏数三内容。这里保留它, 是因为它能将“统计量仍然随机”“示性变量平均”“大数律”三件事接起来; 但数学一复习主干应优先掌握样本均值/方差、 $\chi^2, t, F$  与正态总体抽样分布。除非真题、错题或后续学习需要, 不把 Glivenko–Cantelli 等结果作为考场必背项。

经验分布函数为

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{\{X_i \leq x\}}.$$

固定  $x$  时,  $nF_n(x) \sim \text{Bin}(n, F(x))$ , 所以

$$E[F_n(x)] = F(x), \quad \text{Var}[F_n(x)] = \frac{F(x)[1 - F(x)]}{n}.$$

逐点由强大数律  $F_n(x) \rightarrow F(x)$  几乎必然; 整体则有 Glivenko–Cantelli 一致收敛  $\sup_x |F_n(x) - F(x)| \rightarrow 0$  几乎必然。重复观测值出现  $m$  次时 EDF 跳跃高度是  $m/n$ , 不是固定的  $1/n$ 。

## 5 第四层: 三大分布的生成、密度与分位点

若  $Z_1, \dots, Z_\nu$  独立标准正态,  $Y = \sum Z_i^2 \sim \chi^2(\nu)$ , 且

$$f_Y(y) = \frac{y^{\nu/2-1} e^{-y/2}}{2^{\nu/2} \Gamma(\nu/2)}, \quad y > 0, \quad E(Y) = \nu, \quad \text{Var}(Y) = 2\nu.$$

独立卡方可加:  $\sum_j Y_j \sim \chi^2(\sum_j \nu_j)$ 。它是  $\text{Gamma}(\nu/2, 1/2)$  (率参数) 特例。

若  $Z \sim N(0, 1)$ 、 $Y \sim \chi^2(\nu)$  且独立, 则

$$T = \frac{Z}{\sqrt{Y/\nu}} \sim t(\nu).$$

$t$  关于零对称,  $E(T) = 0$  需  $\nu > 1$ ,  $\text{Var}(T) = \nu/(\nu - 2)$  需  $\nu > 2$ , 且  $t(\nu) \Rightarrow N(0, 1)$  当  $\nu \rightarrow \infty$ 。还要记住  $T^2 \sim F(1, \nu)$ 。

若  $U \sim \chi^2(\nu_1)$ 、 $V \sim \chi^2(\nu_2)$  独立, 则

$$F = \frac{U/\nu_1}{V/\nu_2} \sim F(\nu_1, \nu_2), \quad \frac{1}{F} \sim F(\nu_2, \nu_1).$$

$F$  的支持为正, 分子、分母自由度不可交换; 倒数关系决定分位点换序。




图 7.2 三大抽样分布生成谱系架构 (V16)：从标准正态到  $\chi^2, t, F$  的代数生成关系

三大分布的密度与矩存在边界也属于抽样分布接口。 $t(\nu)$  密度为

$$f_T(t) = \frac{\Gamma((\nu+1)/2)}{\sqrt{\nu\pi} \Gamma(\nu/2)} \left(1 + \frac{t^2}{\nu}\right)^{-(\nu+1)/2}, \quad t \in \mathbb{R},$$

其尾部比正态更厚。 $F(\nu_1, \nu_2)$  密度为

$$f_F(x) = \frac{\Gamma((\nu_1 + \nu_2)/2)}{\Gamma(\nu_1/2)\Gamma(\nu_2/2)} \left(\frac{\nu_1}{\nu_2}\right)^{\nu_1/2} \frac{x^{\nu_1/2-1}}{(1 + \nu_1 x/\nu_2)^{(\nu_1 + \nu_2)/2}}, \quad x > 0.$$

$F$  的期望要求  $\nu_2 > 2$ ，且  $E(F) = \nu_2/(\nu_2 - 2)$ ；方差还要求  $\nu_2 > 4$ 。卡方 MGF 为  $(1 - 2t)^{-\nu/2}$  ( $t < 1/2$ )，可加性也可由 MGF 乘积复原。

对上  $\alpha$  分位点  $c_\alpha$ ，约定  $P(Y > c_\alpha) = \alpha$ 。常用关系为

$$\chi_{1-\alpha}^2(\nu) \neq \chi_\alpha^2(\nu) \text{ 的简单负号关系, } t_{1-\alpha}(\nu) = -t_\alpha(\nu),$$

$$F_{1-\alpha}(\nu_1, \nu_2) = \frac{1}{F_\alpha(\nu_2, \nu_1)}.$$

查表前先确认是上尾还是下尾，双侧问题要拆成  $\alpha/2$ 。




图 7.3 抽样分布分位点与对称/倒数反演 (V17):  $t$  负号对称、 $F$  倒数换序与  $\chi^2$  非对称单尾

## 6 第五层：正态总体的正交分解与精确抽样分布

若  $X_i \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ , 则有以下精确结论。这里沿用全册约定:  $X \perp Y$  表示随机变量概率独立; 单符号  $\perp$  只表示几何正交。

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \bar{X} \perp S^2.$$

几何上, 样本向量分解为常数方向  $(1, \dots, 1)$  的均值投影和其正交残差空间; 正态向量的正交投影独立。于是

$$\frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

均值已知时,  $\sum_i (X_i - \mu)^2 / \sigma^2 \sim \chi^2(n)$ ; 均值未知时估计一个方向, 残差自由度降为  $n-1$ 。

### $\chi^2/t/F$ 的生成链

把样本向量分解为均值方向与残差子空间后, 正态向量的正交投影独立; 残差子空间维数为  $n-1$ , 所以平方和标准化后是  $n-1$  个独立标准正态平方的和, 即  $\chi^2(n-1)$ 。再用独立的  $Z$  除以  $\sqrt{\chi^2(\nu)/\nu}$  得  $t(\nu)$ , 两个独立的标准正态卡方比值得  $F$ 。因此自由度不是表格记号, 而是剩余独立随机方向数; 正态性和样本独立性缺失时, 这条精确生成链停止, 只能转向渐近标尺。

### 自由度账本：先校准尺度，再数方向

| 抽样条件        | 统计量结构                                         | 可输出的精确标尺              |
|-------------|-----------------------------------------------|-----------------------|
| 均值 $\mu$ 已知 | $\sum (X_i - \mu)^2 / \sigma^2$               | $\chi^2(n)$           |
| 均值未知        | $\sum (X_i - \bar{X})^2 / \sigma^2$           | $\chi^2(n-1)$         |
| 两独立正态样本     | $(S_1^2 / \sigma_1^2) / (S_2^2 / \sigma_2^2)$ | $F(n-1, m-1)$         |
| 配对观测        | $D_i = X_i - Y_i$ 后对 $D_i$ 抽样                 | 单样本 $t(n-1)$ (满足正态差值) |

表中每个自由度都来自独立随机方向数, 而不是来自样本量的机械代换。方差比例已知时可以精确校准; 不等方差未知时只能使用 Welch 近似, 不能把它倒填入精确  $F/t$  表。

### 2017 真题：平方和必须先校准尺度

设  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, 1)$ 。判断下列量是否为卡方分布：

$$\sum_{i=1}^n (X_i - \mu)^2, \quad 2(X_n - X_1)^2, \quad \sum_{i=1}^n (X_i - \bar{X})^2, \quad n(\bar{X} - \mu)^2.$$

前者是  $n$  个独立标准正态方向的平方和, 服从  $\chi^2(n)$ ; 残差平方和是正交残差子空间的  $n-1$  个方向, 服从  $\chi^2(n-1)$ ; 均值方向满足  $\sqrt{n}(\bar{X} - \mu) \sim N(0, 1)$ , 故其平方服从  $\chi^2(1)$ 。但  $X_n - X_1 \sim N(0, 2)$ , 所以

$$\frac{(X_n - X_1)^2}{2} \sim \chi^2(1), \quad 2(X_n - X_1)^2 = 4\chi^2(1),$$

并非  $\chi^2(1)$ 。得分链不是“看到平方就数自由度”, 而是“先恢复标准正态尺度, 再数独立方向”。

## 7 第六层：两个独立正态总体与配对结构

若两组独立正态样本的方差已知，则

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{\sigma_1^2/n_1 + \sigma_2^2/n_2}} \sim N(0, 1).$$

方差比的枢轴量为

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1 - 1, n_2 - 1).$$

等方差未知时定义

$$S_p^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2},$$

则

$$\frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{S_p \sqrt{1/n_1 + 1/n_2}} \sim t(n_1 + n_2 - 2).$$

方差不等时不能硬套合并方差  $t$ ，应使用 Welch 统计量

$$T_W = \frac{(\bar{X} - \bar{Y}) - (\mu_1 - \mu_2)}{\sqrt{S_1^2/n_1 + S_2^2/n_2}},$$

其 Welch-Satterthwaite 自由度是近似值。配对数据先取  $D_i = X_i - Y_i$ ，再对  $D_i$  使用单样本  $t$ ，不能当作两组独立样本。

显式的 Welch 自由度近似为

$$\nu_W \approx \frac{(S_1^2/n_1 + S_2^2/n_2)^2}{(S_1^2/n_1)^2/(n_1 - 1) + (S_2^2/n_2)^2/(n_2 - 1)}.$$

若观测是成对的  $(X_i, Y_i)$ ，总体相关性不能被忽略；应先分析差值  $D_i$  的均值、方差和正态性，配对结构的优点是消除个体内共同波动，而不是增加样本独立性。

### 真题动作链：2021 Q 九的配对均值差

设  $(X_i, Y_i)$  是二维正态总体的简单随机样本，跨  $i$  独立，而同一对内相关系数为  $\rho$ 。令  $D_i = X_i - Y_i$ ，则

$$\hat{\theta} = \bar{X} - \bar{Y} = \frac{1}{n} \sum_{i=1}^n D_i, \quad E(D_i) = \mu_1 - \mu_2, \quad \text{Var}(D_i) = \sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2.$$

因此

$$E(\hat{\theta}) = \mu_1 - \mu_2, \quad \text{Var}(\hat{\theta}) = \frac{\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2}{n}.$$

若继续做检验，应把  $D_1, \dots, D_n$  当作一个正态总体的单样本，而不是把  $\bar{X}$ 、 $\bar{Y}$  当作两个独立样本；只有跨对独立，不能删除同对协方差。配对设计先压缩为差值，再决定单样本标尺。

### 配对与独立两样本的边界

独立两样本的均值差方差为  $\sigma_1^2/n_1 + \sigma_2^2/n_2$ ；配对数据必须保留  $-2\text{Cov}(X_i, Y_i)$ 。2021 Q 九属于配对接口；2023 Q 九则是独立正态样本且方差比已知的精确  $F$  接口。两题都出现“两组数据”，但生成结构、统计量和可用分布完全不同。



## 7.1 二元总体的样本均值接口

若每个观测是随机向量  $(X_i, Y_i)$ ，均值向量为  $(\mu_X, \mu_Y)$ ，协方差为  $\text{Cov}(X, Y) = \sigma_{XY}$ ，且样本对之间独立，则

$$E(\bar{X}, \bar{Y}) = (\mu_X, \mu_Y),$$

$$\text{Cov}(\bar{X}, \bar{Y}) = \frac{\sigma_{XY}}{n}, \quad \text{Corr}(\bar{X}, \bar{Y}) = \text{Corr}(X, Y).$$

因此样本均值可以降低共同波动的绝对量级，但不能自动消除原总体的相关结构；二维正态时均值向量仍为二维正态，协方差矩阵缩小为原矩阵的  $1/n$ 。

## 8 第七层：精确与渐近分流

正态总体给出任意  $n$  的精确  $Z, \chi^2, t, F$ ；一般总体若方差有限，只能由 LLN、CLT 与 Slutsky 得到大样本近似。于是

$$\frac{\sqrt{n}(\bar{X} - \mu)}{S} \xrightarrow{d} N(0, 1)$$

通常不是精确  $t$ 。抽样分布研究的是统计量的理论随机性，不能与某一次数据的经验分布混淆。

## 9 第八层：统一工作流与边界

1. 先写总体、样本量、独立性、正态性和方差条件；有限总体不放回时不能默认 i.i.d。
2. 判断统计量是样本函数还是已经代入观测值；检查公式中是否含未知参数。
3. 均值/方差问题先使用样本恒等式；顺序问题先转成二项计数；EDF 问题先写示性变量平均。
4. 正态样本中先拆均值方向与残差方向，再匹配  $\chi^2, t, F$ ；自由度等于独立随机方向数。
5. 两样本先分清独立/配对、等方差/不等方差，最后确认精确分布还是渐近近似与分位点尾部。

### 不可省略的边界

$t, \chi^2, F$  的精确结论依赖正态总体； $\bar{X}$  与  $S^2$  的独立性不是一般分布事实； $S^2$  无偏不等于  $S$  无偏；分母自由度和  $F$  分布参数顺序不能凭记忆交换；CLT 的渐近正态不能替代有限样本精确分布。

## 10 第九层：真题证明链——从随机方向到估计校准

本节把几个容易被压缩成“背分布表”的真题还原成可检查的生成过程。每题的共同入口不是题号，而是：先确认统计量由哪些随机方向组成，再确认尺度、自由度和评价目标。

### 2005 Q 十四：一个选项同时考尺度、独立性与自由度

设  $X_i \stackrel{\text{i.i.d.}}{\sim} N(0, 1)$ ， $\bar{X}$  为均值， $S^2$  为无偏样本方差。由

$$\sqrt{n} \bar{X} \sim N(0, 1), \quad (n-1)S^2 \sim \chi^2(n-1),$$

且  $\bar{X} \perp S^2$ ，可得

$$\frac{\sqrt{n} \bar{X}}{S} = \frac{Z}{\sqrt{\chi^2(n-1)/(n-1)}} \sim t(n-1).$$



因此  $n\bar{X}$  不能直接当标准正态,  $nS^2$  不能直接当  $\chi^2(n)$ ;  $t$  的分子必须是标准正态方向, 不能只因为“均值与方差独立”就任意拼接。该题的检查顺序是“标准化尺度  $\rightarrow$  独立性  $\rightarrow$  自由度”。

### 2005 Q 二十三与 2008 Q 二十三: 中心化会制造约束, 但仍能构造无偏估计

令  $Y_i = X_i - \bar{X}$ 。因为  $\sum_i Y_i = 0$ , 对  $i \neq j$  有

$$\text{Var}(Y_i) = \sigma^2 \left(1 - \frac{1}{n}\right), \quad \text{Cov}(Y_i, Y_j) = -\frac{\sigma^2}{n}.$$

所以残差分量不独立; 正态性只把均值方向与残差子空间分开。另一方面, 正态样本中

$$E(\bar{X}^2) = \mu^2 + \frac{\sigma^2}{n}, \quad E(S^2) = \sigma^2,$$

故

$$T = \bar{X}^2 - \frac{S^2}{n} \quad \text{满足} \quad E(T) = \mu^2.$$

当  $\mu = 0, \sigma = 1$  时,  $\bar{X}^2 \sim \chi^2(1)/n$ , 且与  $S^2$  独立, 从而

$$\text{Var}(T) = \frac{2}{n^2} + \frac{1}{n^2} \frac{2}{n-1} = \frac{2}{n(n-1)}.$$

同一组样本既显示“残差不能当独立分量”, 又显示“均值方向与残差标尺可以独立组合”。

### 2011 Q 二十三: 均值是否已知决定损失几个方向

若总体为  $N(\mu_0, \sigma^2)$  且  $\mu_0$  已知, 方差的最大似然估计为

$$\widehat{\sigma^2} = \frac{1}{n} \sum_{i=1}^n (X_i - \mu_0)^2, \quad \frac{n\widehat{\sigma^2}}{\sigma^2} \sim \chi^2(n).$$

因此  $E(\widehat{\sigma^2}) = \sigma^2$ ,  $\text{Var}(\widehat{\sigma^2}) = 2\sigma^4/n$ 。只有在用  $\bar{X}$  估计未知均值时, 才把一个方向用于中心化, 改为  $n-1$  个残差方向。看到“已知均值”必须在套卡方表前先改自由度。

### 2013 Q 八: 平方变换要保留两个原像

若  $X \sim t(n)$ 、 $Y \sim F(1, n)$ , 则  $Y$  与  $X^2$  同分布, 即  $Y \stackrel{d}{=} X^2$ 。当  $c > 0$  且  $P(X > c) = \alpha$  时,  $t$  分布关于零对称, 故

$$P(Y > c^2) = P(|X| > c) = P(X > c) + P(X < -c) = 2\alpha.$$

这里的 2 不是记忆常数, 而是平方映射  $x \mapsto x^2$  的两个原像  $c$  与  $-c$ ; 若忘记非单调变换的原像数量, 就会把答案误写成  $\alpha$ 。

### 2023 Q 九: 方差比已知时是精确 $F$ , 不能外推成 Welch

若两独立正态总体的方差分别为  $\sigma^2$  与  $2\sigma^2$ , 样本方差为  $S_1^2, S_2^2$ , 则

$$\frac{(n-1)S_1^2}{\sigma^2} \sim \chi^2(n-1), \quad \frac{(m-1)S_2^2}{2\sigma^2} \sim \chi^2(m-1),$$

且二者独立。因此

$$\frac{S_1^2}{S_2^2/2} \sim F(n-1, m-1).$$

必须先除以各自真实方差，再形成独立卡方比。题面给定方差比时这是有限样本精确结论；两方差都未知且不等时，均值比较的 Welch 自由度只是近似值，不能由本题偷换得到精确  $t$ 。

### 顺序统计量的跨模型证据：1996、2003、2023、2024

离散总体中，最大值必须从  $F(x)^n$  的跳跃得到原子质量；联合最大/最小还需区分  $x=y$  的相等路径与  $x>y$  的两种排列（1996 Q 十一）。连续总体中，若  $X_{(1)}$  是带参数下界  $\theta$  的最小值，先求其 CDF/密度再取期望，不能把最小值直接视为无偏估计（2003 Q 十二）。若

$$F(x; \theta) = \frac{x^3}{\theta^3}, \quad 0 < x < \theta,$$

则  $n=3$  时最大值密度为

$$f_{X_{(3)}}(t) = 3F(t)^2 f(t) = \frac{9t^8}{\theta^9}, \quad 0 < t < \theta,$$

于是  $E[X_{(3)}] = 9\theta/10$ ，无偏系数为  $10/9$ （2023 Q 二十三）。均匀总体最大值也先由同一 CDF 计数得到分布，但无偏系数与最小 MSE 系数分别为  $(n+1)/n$  与  $(n+2)/(n+1)$ （2024 Q 二十二）。所以稳定接口是

$$\boxed{\text{CDF/原子计数} \rightarrow \text{分布} \rightarrow E(T), E(T^2) \rightarrow \text{无偏或 MSE 校准}}.$$

对 2024 Q 二十二的均匀总体  $X_i \sim U(0, \theta)$ ，令  $T = X_{(n)}$ ，则

$$E(T) = \frac{n}{n+1}\theta, \quad E(T^2) = \frac{n}{n+2}\theta^2.$$

对线性估计量  $cT$ ，无偏条件直接给出

$$E(cT) = \theta \implies c_{\text{unb}} = \frac{n+1}{n}.$$

若目标改为最小化均方误差，必须保留完整风险函数：

$$\begin{aligned} h(c) &= E[(cT - \theta)^2] \\ &= c^2 \frac{n}{n+2}\theta^2 - 2c \frac{n}{n+1}\theta^2 + \theta^2. \end{aligned}$$

这是关于  $c$  的严格凸二次函数，令  $h'(c) = 0$  得

$$c_{\text{MSE}} = \frac{n+2}{n+1}, \quad h(c_{\text{MSE}}) = \frac{\theta^2}{(n+1)^2}.$$

因此两个系数来自两个不同的输出目标，不能把无偏系数当成最小 MSE 系数。

### 2016 真题：参数支撑使最大值的幂次变为 9

若  $X_i$  的密度为

$$f(x; \theta) = \frac{3x^2}{\theta^3} I_{(0, \theta)}(x), \quad i = 1, 2, 3,$$

则总体 CDF 为  $F(x) = (x/\theta)^3$ 。最大值  $T = X_{(3)}$  满足

$$F_T(t) = P(T \leq t) = F(t)^3 = \left(\frac{t}{\theta}\right)^9, \quad 0 < t < \theta,$$

故

$$f_T(t) = \frac{9t^8}{\theta^9}, \quad \int_0^\theta f_T(t) dt = 1,$$

并且

$$E(T) = \int_0^\theta t \frac{9t^8}{\theta^9} dt = \frac{9}{10}\theta.$$

若要求  $aT$  无偏估计  $\theta$ ，必须单独解  $aE(T) = \theta$ ，得到

$$a = \frac{10}{9}.$$

指数 9 来自“总体 CDF 的三次幂再叠加样本最大值的三次计数”，不是把样本量 3 机械写进密度。该题只要求无偏校准，完成  $E(T)$  后停止，不需要继续计算 MSE。

## 11 贯穿母例：一组正态样本的三种随机标尺

母例：从样本到  $\chi^2$ 、 $t$  与区间入口

设  $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ 。抽样前先区分对象： $\bar{X}$  和  $S^2$  是统计量，观测到  $\bar{x}, s^2$  后才是数值。平方和分解给出

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1), \quad \bar{X} \perp\!\!\!\perp S^2.$$

均值方向标准化为  $Z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$ ，与独立的残差标尺组合得到

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1).$$

所以同一个样本可以分别提供方差标尺、均值标尺和后续区间/检验的枢轴入口；若总体不正态，不能保留这些有限样本精确结论，只能根据 Topic 06 的条件改用渐近路径。

## 12 一页压缩

一句话总结

样本均值除以未知方差生成  $t$  分布，样本方差除以总体方差生成  $\chi^2$  分布，正态样本均值与方差严格独立。

完全相关的正态变量先校准斜率：2008 真题

若  $X \sim N(0, 1)$ 、 $Y \sim N(1, 4)$  且  $\rho_{XY} = 1$ ，则完全正相关意味着

$$Y - 1 = \frac{\sigma_Y}{\sigma_X}(X - 0) = 2X \quad \text{a.s.},$$

即  $Y = 2X + 1$ 。相关系数达到 1 时要同时校准标准差给出的斜率和均值给出的截距，不能只凭“正相关”写成  $Y = X$ 。