

文件系统：名称、对象、索引与持久化

从路径、fd、inode、块映射到页缓存、日志与崩溃一致性

408 专题手册 · 操作系统文件系统篇

核心模型：文件系统建立持久对象世界

文件系统在块式持久存储之上，为程序制造一个看起来拥有**名字、对象、层次、共享、保护、随机访问与长期存在**的世界。

分析主线：

Name → Object → Open State → Byte Range
→ Cached Page → Block Mapping → Persistent State

横向始终检查三个约束：

Protection

Lifecycle

Crash Consistency

学生版一句话：先找到“谁”，再建立访问关系，再找到“哪一段数据”，最后保证它即使掉电也仍然是一个合法文件。

术语预备：名字、对象与持久数据

- **文件对象**：可按字节读写并具有生命周期的逻辑对象；**文件名**只是目录中指向它的一条名称记录，不是对象身份本身。
- **元数据 (metadata)**：描述对象类型、大小、权限、时间、所有者和数据位置的信息；它与文件内容分开管理。
- **目录项 (directory entry)**：目录文件中的“名字 o 对象标识”记录；**dentry** 是 Linux VFS 在内存中缓存路径组件的对象，不能直接当成磁盘目录项。
- **FCB/inode**：FCB 是教材中的文件控制块；inode 是 Unix 类系统保存文件身份、元数据和数据定位信息的结构。两者都不是文件名本身。
- **文件描述符 (fd)**：进程文件描述符表中的小整数索引；**OFD** 是它指向的打开文件对象，保存当前偏移和打开方式；**fd**、**OFD**、**inode** 是三层不同对象。
- **ACL**：Access Control List，按对象记录哪些主体拥有何种权限；**Capability**：按主体持有可访问对象及权限的凭证集合。
- **VFS**：Virtual File System，向应用提供统一的文件 API，并把路径操作转发给具体文件系统实现；**mount** 把一个文件系统接入现有目录命名空间。
- **页缓存 (Page Cache)**：以内存页为单位缓存文件内容，供普通读写和 **mmap** 共享；它不是 CPU 的硬件 Cache。
- **日志/预写日志 (Journaling/WAL)**：先把元数据变更意图按规定顺序写入日志，崩溃恢复时据此重放或撤销，保证文件系统结构不落入非法中间状态。

后文遇到路径、**open**、**fork**、硬链接或 **mmap** 时，都沿着“名字 o 对象 o 打开引用 o 数据位置 o 持久化约束”这条链判断。

系统的通用推理：崩溃一致性 (Crash Consistency) 中的元数据不变量

在文件系统持久化与崩溃恢复中，同样遵循 OS 通用系统推理引擎 (OS System Reasoning Engine)：

State (Bitmap/Inode/Data Blocks) → Crash/Power Fault (突发断电)
 → Failure (块被重复分配/孤立)
 → Invariant (Bitmap Free $\iff$ 无 Inode 占用)

为了拦截这类毁坏性坏状态，文件系统引入了**预写日志 (Journaling / WAL)** 或**写顺序约束 (Write-Ordering)** 作为最小机制，确保磁盘元数据在故障恢复后依然满足逻辑一致性。

目录

1 第 0 章：文件系统究竟解决什么问题	3
1.1 从裸块设备到“文件世界”	3
1.2 五层映射 + 一个持久化约束	3

2 Part I：名字怎样找到对象	4
3 第 1 章：文件抽象、元数据与对象身份	4
3.1 文件不是“磁盘上一段连续字节”	4
3.2 FCB、inode 与“文件名在哪”	4
3.3 文件逻辑结构、访问方式与物理分配的三层辨析	5
3.4 文件保护模型：Access Matrix 与 ACL / Capability 投影	5
4 第 2 章：目录、路径与链接——从名字到对象	6
4.1 目录：把文件名映射到文件对象	6
4.2 路径解析不是“一次查表”，而是状态推进	6
4.3 绝对路径、相对路径与搜索起点	6
4.4 硬链接：多个名字，同一个对象	7
4.5 符号链接：一个独立对象，内容解释为路径	7
5 第 3 章：VFS 与 Mount——把多个文件系统拼成一个命名空间	7
5.1 为什么需要 VFS	7
5.2 VFS 四类核心对象的职责	8
5.3 Mount：路径经过挂载点时切换文件系统实例	8
6 Part II：进程怎样引用已经找到的文件	8
7 第 4 章：fd、打开文件描述与 inode	8
7.1 为什么不能让 fd 直接等于 inode	8
7.2 三种最重要的共享关系	9
7.3 一个稳定的题目判断法	9
8 第 5 章：文件生命周期——名字引用与打开引用是两套生命线	9
8.1 unlink 删除的首先是一条命名边	9
8.2 双生命周期模型	10
8.3 create、link、unlink、rename 分别改什么	10
9 第 6 章：文件保护——谁可以对哪个对象做什么	10
10 Part III：文件中的字节怎样落到块上	11
11 第 7 章：从文件偏移到逻辑块	11
12 第 8 章：文件物理结构——三种经典方案从矛盾中产生	11
12.1 连续分配：数组模型	11

12.2 链接分配：链表模型	11
12.3 索引分配：映射表模型	11
13 第 9 章：inode 多级索引——最大文件与 I/O 次数计算	12
13.1 经典 UNIX-style mixed indexing	12
13.2 I/O 次数一定先写缓存假设	12
14 Part IV：空间从哪里来——Global Layout 与 Free Space	13
15 第 10 章：文件系统全局 Layout	13
15.1 为什么必须有全局账本	13
16 第 11 章：外存空闲空间管理	14
16.1 位图 Bitmap	14
16.2 空闲链表 Free List	14
16.3 成组链接 Grouped Linking	14
16.4 计数法 Counting	14
17 Part V：文件操作怎样改变内核状态	14
18 第 12 章：一次 open() 的一生	14
18.1 open 的高层语义	14
18.2 open 题型的状态跟踪	15
19 第 13 章：一次 read(fd, buf, n) 的文件系统路径	15
19.1 先定位打开实例，再定位文件位置	15
19.2 现代 buffered read：先问页缓存	15
19.3 跨块读取	15
20 第 14 章：一次 write(fd, buf, n) 的文件系统路径	16
20.1 Buffered write 的核心状态变化	16
20.2 写入可能同时修改哪些状态	16
21 第 15 章：create、close、unlink、rename 的状态机	16
21.1 create：先创造身份，再绑定名字	16
21.2 close：释放一个 handle，不等于删除文件	17
21.3 rename：名字变化不等于内容复制	17
22 Part VI：为什么“写完”以后文件系统仍可能坏	17
23 第 16 章：Crash Consistency——持久状态机的核心问题	17

23.1 高层一次操作，底层多次写	17
23.2 崩溃分析五步法	18
24 第 17 章：fsck 与 Journaling	18
24.1 fsck：允许不一致，重启后扫描修复	18
24.2 Journaling：先记录一笔可重放的事务	18
24.3 Consistency 与 Durability 不完全是一件事	18
25 Part VII：408 计算与解题工具箱	19
26 第 18 章：经典计算模型	19
26.1 模型 A：最大文件大小	19
26.2 模型 B：判断目标字节属于哪一级索引	19
26.3 模型 C：磁盘 I/O 次数	19
26.4 模型 D：路径查找 I/O	19
27 第 19 章：高频辨析表	20
28 第 20 章：文件系统十四问——解题检查表	21
29 第 21 章：五道综合题，把整册重新跑一遍	21
30 附录 A：考试模型 / 机制 / 工程边界	22
31 附录 B：参考资料与工程边界	22

1 第 0 章：文件系统究竟解决什么问题

1.1 从裸块设备到“文件世界”

假设底层只给你一串可以读写的编号块：

$$B_0, B_1, B_2, \dots, B_{N-1}.$$

单靠这些块，应用无法自然回答：

- 这堆字节叫什么名字？目录层次在哪里？
- 这段数据属于哪个逻辑对象？对象有多大、谁拥有、谁能读写？
- 文件增长以后，新块从哪里来？删除以后空间怎样回收？
- 多个名字、多个进程能否指向同一对象？
- 内存缓存和磁盘状态不同步时，什么叫“写成功”？
- 创建文件需要改多个磁盘结构，掉电发生在中间怎么办？


因此文件系统至少提供四个承诺：

承诺	对应用提供的幻觉/抽象	内核必须解决的问题
Naming	用路径而不是块号找对象	目录、路径解析、mount、链接
Object	把字节组织成“文件”	inode/FCB、元数据、权限
Access	打开后可持续读写	fd、打开文件描述（OFD）、offset
Persistence	重启后对象仍可解释	layout、分配、写回、日志、恢复

文件系统与前面专题的边界

- **I/O 专题**回答：已经知道要访问哪个块以后，请求如何提交、DMA 如何搬运、设备如何完成、进程如何被唤醒。
- **虚拟内存专题**回答：虚拟页怎样映射到物理页；`mmap()` 时文件页怎样成为虚拟地址的后备对象。
- **文件系统专题**回答：`/a/b/c` 或 `fd=3` 怎样变成文件对象、文件偏移与存储位置，以及这些持久元数据怎样保持一致。

1.2 五层映射 + 一个持久化约束



文件系统六问

- 以后任何文件系统机制，都先问：
- 1. 名字怎样找到对象？
 - 2. 进程怎样在打开以后持续引用对象？
 - 3. 文件中的字节位置怎样找到逻辑块/页？
 - 4. 逻辑块怎样找到持久存储位置？
 - 5. 新空间怎样分配、旧空间怎样回收？
 - 6. 高层操作由多次持久写组成时，怎样抵抗崩溃？

2 Part I：名字怎样找到对象

3 第 1 章：文件抽象、元数据与对象身份

3.1 文件不是“磁盘上一段连续字节”

- 从应用角度，普通文件最稳定的抽象通常是一个可按字节定位的持久对象。它同时拥有：
- 内容（data）；
 - 大小、权限、所有者、时间戳等元数据（metadata）；
 - 在特定文件系统对象身份；
 - 将逻辑位置映射到存储空间的方法。

元数据与数据分离

UNIX/inode 思想的关键不是“inode 这个单词”，而是把对象身份与元数据从名字和数据内容中拆开：

Name ≠ Object ≠ Data

文件名属于命名空间；inode/FCB 描述对象；数据块保存内容。正因为三者解耦，硬链接、rename、权限修改与共享才有清晰语义。

3.2 FCB、inode 与“文件名在哪”

概念	408 稳定理解	UNIX/Linux 典型映射
FCB	描述文件的控制信息/元数据的抽象	inode 可看作一种具体 FCB 风格实现
inode	对象元数据 + 数据定位信息，不以文件名作为身份	磁盘 inode 与内存 inode object
Directory Entry	把目录中的一个名字映射到对象标识	经典 inode FS 中常是 name → inode number

dentry 不能与“磁盘目录项”混成一个东西

408 中的目录项通常指持久目录文件里的记录；Linux VFS 的 struct dentry 是内存中的路径组件/名称缓存对象。Linux VFS 文档明确说明 dentry 存在于 RAM、用于 pathname lookup，不保存到磁盘。正式做题时先判断题目说的是“目录文件里的 entry”还是“VFS dentry”。

3.3 文件逻辑结构、访问方式与物理分配的三层辨析

408 经常考查文件的不同维度，必须严格区分这三个独立概念：

Logical Structure ≠ Access Method ≠ Physical Allocation

文件系统维度	核心定义与视角	典型实现/分类形式
逻辑结构 (Logical Structure)	** 应用程序 ** 看得到的数据组织形式	无结构流式字节文件、记录式文件（顺序/索引记录）
访问方式 (Access Method)	** 应用程序 ** 从文件中读取/写入数据的接口模式	顺序访问 (Sequential)、直接/随机访问 (Direct/Random)、索引访问
物理分配 (Physical Allocation)	** 操作系统/文件系统 ** 将数据安排落到外存块上的方法	连续分配 (Contiguous)、链接分配 (Linked)、索引分配 (Indexed)

选择文件逻辑结构时看什么

流式文件把内容看成无解释的字节序列；记录式文件再按记录组织。记录式文件中，顺序文件适合按序扫描，索引文件用索引快速定位记录，索引顺序文件兼顾范围检索与顺序处理，散列文件则用 hash 直接定位但不擅长有序遍历。这里讨论的是“应用看到怎样的数据”，不能拿它替换连续/链接/索引分配的外存布局。

3.4 文件保护模型：Access Matrix 与 ACL / Capability 投影

文件的保护与安全机制建立了“谁可以对哪个对象做什么动作”的边界。

通用保护模型：访问矩阵 (Access Matrix) 任何系统保护抽象都可表示为一个二维访问矩阵 AccessMatrix：

AccessMatrix[Subject / Domain, Object] = Rights

其中行代表主体/保护域 (Subject/Domain，如用户、进程、角色)，列代表受保护对象 (Object，如文件、目录、设备)，矩阵元素表示具体的许可权限（如 r, w, x ）。

由于系统中的主体和对象极其庞大，矩阵通常非常稀疏。工程中有两种天然的二维存储投影：

投影方式	存储组织与定义	典型实例与特性
按列 (Object) 存储 ACL	→ 将列上的主体及其权限挂在 ** 对象 (File)** 下；形式为：Object → {(Subject _i , Rights _i)}	** 访问控制列表 (Access Control List)**；如 Linux 文件 <code>rwxr-xr--</code> 、posix ACL。删除文件时易一并回收。
按行 (Subject) 存储 Capability	→ 将行上的对象及其权限挂在 ** 主体 (Domain)** 手里；形式为：Subject → {(Object _j , Rights _j)}	** 能力列表 (Capability List)**；进程持有一组令牌/凭证。传递与撤销权限粒度更细，但查询“某文件被谁有权访问”开销高。

ACL 与 Capability 都来自访问矩阵

ACL 与 Capability 根本不是两个孤立无因的名词，它们是 ** 同一个 Access Matrix 的两种存储切割与二维矩阵投影 **！

4 第 2 章：目录、路径与链接——从名字到对象

4.1 目录：把文件名映射到文件对象

在经典 inode 文件系统里，可把目录理解成特殊文件，其内容逻辑上保存：

filename → inode number

因此删除名字与删除对象是两件不同的事；硬链接也不再神秘：它只是**增加一条新的 name → same object 映射**。

4.2 路径解析不是“一次查表”，而是状态推进

解析绝对路径 `/home/user/a.txt` 时，可以抽象为：

$$D_0 \xrightarrow{home} D_1 \xrightarrow{user} D_2 \xrightarrow{a.txt} I.$$

每一步都以“当前目录对象”为状态，以“下一个 pathname component”为输入，执行 lookup 得到下一个对象。




图 1：路径解析：先沿目录逐级推进，dcache 是可选快路径，而不是磁盘目录项本身。

4.3 绝对路径、相对路径与搜索起点

- 绝对路径通常从进程可见的 root 开始；
- 相对路径从 current working directory 开始；

- `openat()` 一类接口允许把“起点目录”显式变成一个目录 `fd`，从而减少对全局 `cwd` 的依赖并避免部分 `pathname race`。

4.4 硬链接：多个名字，同一个对象

$$\text{name}_1 \dashrightarrow I_X \dashleftarrow \text{name}_2.$$

核心结论：

- 两个名字地位对等；
- 创建硬链接增加对象的 `link count`；
- 删除一个目录项只删除一条命名边；
- 通常不能跨文件系统，因为 `inode number`/对象身份属于具体文件系统；
- 普通用户通常不能随意为目录建立硬链接，以免命名空间产生复杂环路。

4.5 符号链接：一个独立对象，内容解释为路径

符号链接本身有自己的文件对象/元数据，其内容语义上是目标 `pathname`。路径解析遇到 `symlink` 时，会根据规则继续解析目标路径，因此：

- 可跨文件系统；
- 可指向目录；
- 目标删除后 `symlink` 仍存在，但可能变成 `dangling link`；
- 它增加的是“路径解释层”，不是目标 `inode` 的 `link count`。

相对符号链接保存的是路径字符串，解析起点通常是链接所在目录；绝对符号链接从根开始。删除目标只会留下 `dangling link`，不会自动删除链接对象。硬链接与符号链接的判断顺序应固定为：是否共享同一 `inode`、是否增加目标 `link count`、能否跨文件系统、目标删除后是否仍可沿链接访问。

5 第 3 章：VFS 与 Mount——把多个文件系统拼成一个命名空间

5.1 为什么需要 VFS

如果每种文件系统都让应用调用不同 API，那么 `open/read/write/stat` 无法成为统一接口。VFS 的作用是：

Common filesystem API $\rightarrow$ polymorphic filesystem operations

它既向用户空间提供统一文件接口，也在内核中允许 `ext4`、`tmpfs`、`NFS` 等不同实现共存。

5.2 VFS 四类核心对象的职责

对象	回答的问题	稳定心智模型
superblock	这是哪个已挂载文件系统实例?	文件系统级状态/操作集合
inode	这个文件系统对象是谁?	元数据、权限、对象级操作
dentry	这个名字组件当前解析到谁?	内存 pathname cache/object binding
file	这一次打开实例怎样访问对象?	offset、status flags、访问操作




图 2: VFS 四对象：图中虚线统一表示“引用/关联”，不与动态控制流混淆。

5.3 Mount：路径经过挂载点时切换文件系统实例

挂载不是“把磁盘内容复制进目录”，而是让 pathname walk 到达某个 mount point 时，切换到另一个文件系统实例的根对象。因此：

one namespace tree ≠ one physical filesystem

同一路径树可以跨越多个 superblock/文件系统实例。

考试范围边界

408 常见范围包括文件元数据与 inode、文件操作、文件保护、逻辑/物理结构、目录、硬/软链接、文件系统全局布局、空闲空间管理、VFS 与挂载。Journaling、extents、dcache/XArray 用于深化机制或说明工程边界，不替代教材模型。

6 Part II：进程怎样引用已经找到的文件

7 第 4 章：fd、打开文件描述与 inode

7.1 为什么不能让 fd 直接等于 inode

如果 fd 直接指向 inode, 那么同一文件被独立打开两次时, 两个访问者如何拥有独立 offset? O_APPEND 等“打开实例状态”又放哪里?

于是必须增加一层：

fd → 打开文件描述（OFD） → inode

POSIX 语义中, 每次成功 open() 创建一个新的打开文件描述 (open file description, OFD); 文件 offset 和 file status flags 属于它, 而 fd 只是进程内的句柄。

7.2 三种最重要的共享关系




图 3: 独立 open 产生独立 OFD; fork 后对应 fd 引用同一 OFD, 因此共享 file offset。




图 4: dup 不会再次 open, 而是增加一个 fd 句柄指向同一个 OFD。

7.3 一个稳定的题目判断法

遇到“offset 是否共享”时, 不要背父子/进程关系, 直接问:

Do these descriptors refer to the same OFD?

- 独立 open(): 通常不同 OFD, offset 独立;
- dup/dup2(): 同一 OFD, offset 共享;
- fork(): 子进程 fd 与父进程对应 fd 指向同一 OFD, offset 共享;
- exec(): 不是创建新进程; 未被 close-on-exec 关闭的 fd 可继续存在。

不要把“系统级打开文件表”想成“每个文件只有一个表项”

一个 inode 可以同时被多个 OFD 引用。文件对象身份和打开实例状态必须分开, 否则无法解释“同一文件独立打开两次 offset 不共享”。

8 第 5 章：文件生命周期——名字引用与打开引用是两套生命线

8.1 unlink 删除的首先是一条命名边

POSIX unlink() 的稳定语义是：删除 directory entry/link 并递减 link count。若最后一个 link 已删除但仍有打开引用, 文件内容的最终回收要推迟到这些引用关闭。




图 5: unlink while open: 名字可以消失, 而已经建立的打开引用继续访问同一对象。

8.2 双生命周期模型

- **Name lifetime:** 有多少持久目录链接仍指向对象? (经典 UNIX 用 link count 表达)
- **打开引用生命周期:** 运行时是否仍有 OFD 或其他内核引用使对象继续存活?

可以直接使用的结论是:

no persistent names + no live references $\Rightarrow$ eligible for final reclamation

Linux 实现边界

不要把教材中的“打开计数”机械等同于 Linux `inode.i_count`。`struct file`、inode cache、dentry cache 都有各自引用/回收机制。408 做题时可以用“链接引用 + 打开引用”两类计数理解生命周期; 工程实现则更细。

8.3 create、link、unlink、rename 分别改什么

操作	命名空间变化	对象/元数据变化
create	新增 name $\rightarrow$ new object	分配/初始化对象元数据, 通常 link count 从 1 开始
link	新增 second name $\rightarrow$ same object	link count 增加
unlink	删除一条 name $\rightarrow$ object	link count 减少; 是否最终回收看剩余引用
rename	把名字关系从旧位置移动/替换到新位置	通常不改变文件内容本身, 重点是目录元数据的一致更新

9 第 6 章：文件保护——谁可以对哪个对象做什么

文件保护的统一问题是:

Subject $\times$ Object $\times$ Operation $\rightarrow \{allow, deny\}$

408 常见机制包括访问权限, 以及所有者、所属组、其他用户的读写执行位。目录的读、写、执行权限与普通文件语义不同: 目录执行权限表示允许搜索或穿越, 写权限与创建、删除目录项相关。

保护题三问

1. 当前 subject 是谁 (用户/进程/权限域)?
2. 当前 object 是普通文件还是目录?
3. 请求 operation 是读取内容、修改内容、创建名字、删除名字还是穿越目录?

不要只看到“`rwX`”就机械对应同一含义。

10 Part III：文件中的字节怎样落到块上

11 第 7 章：从文件偏移到逻辑块

设文件系统块大小为 B ，字节偏移为 x ：

$$LBN = \left\lfloor \frac{x}{B} \right\rfloor, \quad \text{offset} = x \bmod B.$$

这一步只把文件内部字节位置转换成文件内部逻辑块号，还没有决定它在磁盘哪个位置。

三个“地址”不要混

- File offset：文件内的字节序号；
- LBN：文件自己的逻辑块号；
- filesystem block / device location：底层存储位置。

它们对应的层次不同，不能把 offset/B 的结果直接叫“磁盘块号”。

12 第 8 章：文件物理结构——三种经典方案从矛盾中产生

12.1 连续分配：数组模型

若文件占据连续块区间：

$$PBN = \text{start} + LBN.$$

优点：随机与顺序访问都直接，局部性好。**代价：**增长困难、外部碎片、预估大小困难。

12.2 链接分配：链表模型

每个数据块保存“下一块”的位置：

$$B_0 \rightarrow B_7 \rightarrow B_{19} \rightarrow \dots$$

优点：增长灵活、没有经典外部碎片问题。**代价：**隐式链随机访问差，指针损坏影响链后部。

FAT：把链从数据块搬进集中表 FAT 把“下一簇号”集中存储，使链遍历可在内存 FAT 中进行；因此它仍是 linked allocation 思想，但显著改善了定位开销（在 FAT 已在内存的题设下）。

12.3 索引分配：映射表模型

把数据块地址集中放进索引结构：

$$LBN \xrightarrow{\text{index}} PBN.$$

它和页表有明显同构：都通过增加一层 indirection，换来离散布局、随机定位和灵活增长。

VM 与 File System 的共同设计语言

VPN → Page Table → PFN

和

LBN → File Index → Storage Block

两条路径都采用“逻辑编号 → 映射结构 → 物理位置”。增加映射表后，系统可以移动、共享、稀疏分配或扩展底层空间，而不改变上层使用的逻辑编号。

13 第 9 章：inode 多级索引——最大文件与 I/O 次数计算

13.1 经典 UNIX-style mixed indexing

设一个 inode 中有：

- d 个直接指针；
- s 个一级间接指针；
- q 个二级间接指针；
- t 个三级间接指针。

文件系统块大小为 B ，块地址项大小为 a ，则一个索引块可容纳：

$$K = \left\lfloor \frac{B}{a} \right\rfloor$$

个地址项。

最大可寻址数据块数：

$$N_{max} = d + sK + qK^2 + tK^3$$

最大文件大小：

$$Size_{max} = N_{max} \cdot B$$




图 6: 经典 inode 混合索引。每增加一级间接，就多一次索引块解析机会与空间层级。

13.2 I/O 次数一定先写缓存假设

典型题设“inode 已在内存、相关索引块均未缓存”：

- 直接块：读数据需要 1 次块 I/O；

- 一级间接：索引块 + 数据块，共 2 次；
- 二级间接：两级索引 + 数据，共 3 次；
- 三级间接：三级索引 + 数据，共 4 次。

但如果索引块已缓存，次数会下降。因此任何 I/O 计算都先写：**inode 是否在内存？索引块是否缓存？目录块是否缓存？页缓存是否命中？**

现代 ext4：extent 不是“12+1+1+1”的简单延长

经典 direct/single/double/triple 模型非常适合 408 计算题；现代 ext4 可使用 extent tree，把“连续逻辑范围 → 连续物理范围”作为映射单位。Linux ext4 文档明确区分 inode 的 extent 格式等结构。工程边界用于理解“现代文件系统为何减少大文件映射元数据”，但不替代经典计算模型。

14 Part IV：空间从哪里来——Global Layout 与 Free Space

15 第 10 章：文件系统全局 Layout

15.1 为什么必须有全局账本

文件系统不能只存“每个文件的 inode”。它还必须知道：

- 文件系统总大小与块大小；
- 哪些 inode/数据块空闲；
- inode table 在哪里；
- 根对象与挂载状态；
- 日志、特性标志、校验信息等。

因此出现 superblock、bitmap、inode table、data region 等全局结构。

结构	解决的问题	典型信息
Superblock	这个文件系统实例整体是什么？	block size、总量、特性、状态等
Inode bitmap	哪些 inode identity 可分配？	每个 inode 的 free/used 状态
Block bitmap	哪些 data/fs blocks 可分配？	每块 free/used 状态
Inode table	每个对象元数据持久放在哪里？	inode records
Data region	文件/目录的内容在哪里？	data blocks / index / extents
Journal（扩展）	多结构更新如何恢复？	transaction records / commit

ext4 block groups

现代 ext4 会把磁盘划成 block groups，并在组内组织 bitmap、inode table 与数据块，以提高局部性并减少碎片/寻道成本。它说明一个更普遍的设计原则：**空间分配不仅追求“能分到”，还追求 metadata 与 data 的局部性。**

16 第 11 章：外存空闲空间管理

16.1 位图 Bitmap

用 1 bit 表示一个单位是否空闲。优点是结构紧凑，寻找连续空闲范围和统计较方便；代价是需要扫描/维护位图并保持一致性。

16.2 空闲链表 Free List

把空闲块串起来。结构简单，但想找一段连续空间或一次分配很多块时可能遍历成本高。

16.3 成组链接 Grouped Linking

把若干空闲块号作为一组集中保存，再用某个块连接下一组。经典 UNIX 教学模型用它降低频繁访问长链的成本。

16.4 计数法 Counting

当空闲块经常成片连续时，用：

$(start, count)$

记录一段空闲区。它体现一个普遍优化：不要逐块记录具有强连续性的状态，而要记录范围。

空闲空间问题不要只问“哪个方法快”

固定四问：元数据多大？找一个块快不快？找连续 k 块快不快？回收/合并是否方便？不同 workload 下不存在绝对最好方案。

位图题还要先确定“1 表示空闲还是已用”的题设约定，再按块号定位 bit；成组链接的组首保存若干空闲块号，最后一个入口指向下一组，组满/组空时才发生组间搬移。计数法适合连续空闲区，空闲链表适合简单回收，位图适合快速判断单块状态；选择取决于查询对象是单块还是连续范围。

17 Part V：文件操作怎样改变内核状态

18 第 12 章：一次 open() 的一生

18.1 open 的高层语义

open(path, flags) 不是“把文件内容读进来”，而是建立：

pathname $\rightarrow$ object $\rightarrow$ new OFD $\rightarrow$ fd

其中 open() 的 POSIX 语义包括创建新的 OFD，并让一个 fd 指向它；常规文件初始 offset 通常从文件开头开始（特定 flag 另行处理）。




图 7: `open()` 的核心不是读数据，而是把“名字”转成“运行时访问关系”。

18.2 `open` 题型的状态跟踪

1. 路径从哪个起点解析？绝对、`cwd` 还是 `dirfd`？
2. 每个 component 是否命中 `dcache`？如果题目按磁盘 I/O 计数，需要哪些目录块/inode？
3. 最终对象权限是否允许请求模式？
4. 是 independent `open` 还是已有 `fd` 的 `dup/fork` 共享？
5. 返回的 `fd` 是否按题设采用“最小可用非负整数”？

19 第 13 章：一次 `read(fd, buf, n)` 的文件系统路径

19.1 先定位打开实例，再定位文件位置

$$fd \rightarrow OFD \rightarrow \{offset, flags, object\}.$$

随后根据 `offset` 计算文件页/逻辑块位置。

19.2 现代 buffered read：先问页缓存

普通 buffered file I/O 中，更合理的逻辑是：

$$(file, page\ index) \rightarrow Page\ Cache?$$

而不是先无条件算 PBN 再查缓存。若命中，直接从缓存页向用户缓冲提供数据；若未命中，具体文件系统才需要建立文件偏移到存储位置的映射并向 I/O 子系统提交读取。




图 8: `read()` 的文件系统边界：到 I/O request 为止；DMA/interrupt/wakeup 已由 I/O 专题负责。

19.3 跨块读取

如果读取范围跨多个文件页/块，不能只计算起始 LBN：

$$LBN_{start} = \left\lfloor \frac{off}{B} \right\rfloor, \quad LBN_{end} = \left\lfloor \frac{off + n - 1}{B} \right\rfloor.$$

实际读取字节数还受到 EOF 限制。

文件操作状态变化

create 建立对象并把名字接入父目录；**open** 建立新的 OFD 与 fd；**dup/fork** 可共享同一 OFD 及其 offset；**close** 只释放一个句柄引用；**read/write** 推进共享 offset（除非使用显式位置接口）；**lseek** 改变 offset 而不读写数据；**truncate** 改变文件大小并可能释放数据块；**unlink** 删除命名边，仍被打开的对象直到最后一个引用消失才回收。做题时逐项标记 namespace、inode、OFD、fd、offset、data blocks 哪一层改变。

20 第 14 章：一次 write(fd, buf, n) 的文件系统路径

20.1 Buffered write 的核心状态变化

常见普通写路径：

User Data → 页缓存 → Dirty

并更新文件 offset、size/mtime 等相关内存元数据。系统调用返回与“数据已经稳定落盘”不是同一时间点。

与 I/O 专题接口

本册只追到：**dirty cached pages + block mapping + writeback request**。请求提交以后，设备队列、driver、DMA、completion interrupt 等交给 I/O 专题。这样两册之间只有接口，不重复整条设备路径。

20.2 写入可能同时修改哪些状态

- 文件数据页；
- file size（若扩展）；
- mtime/ctime 等元数据；
- block allocation metadata（若需要新块）；
- block mapping/index/extent；
- OFD 的 offset。

正因为一次高层 **write** 可能对应多份持久结构更新，后面才会产生 crash consistency 问题。

21 第 15 章：create、close、unlink、rename 的状态机

21.1 create：先创造身份，再绑定名字

以经典 inode 模型看，新建文件至少需要：

1. 找到父目录；
2. 分配对象身份/inode；

3. 初始化 metadata;
4. 在父目录中建立 $\text{name} \rightarrow \text{inode}$ 映射;
5. 若同时打开, 再创建 OFD 与 fd。

创建空文件时不必立刻拥有数据块; 实际数据块可在后续写入时按需分配。你原有材料把“inode bitmap、inode table、parent directory”识别为核心持久结构, 这是理解 crash consistency 的好入口。

21.2 close: 释放一个 handle, 不等于删除文件

`close(fd)` 首先终止当前 fd 对 OFD 的引用。只有当相应运行时引用都消失, OFD 才可回收; 而持久文件是否存在仍由命名空间链接等状态决定。

21.3 rename: 名字变化不等于内容复制

高层语义重点是对 namespace 的原子式名称变更/替换要求, 而不是“把全部数据重新写一遍”。这也是为什么 rename 常被应用用作构造持久更新协议的一部分, 但具体持久化保证仍要结合文件系统与同步调用分析。

22 Part VI: 为什么“写完”以后文件系统仍可能坏

23 第 16 章: Crash Consistency——持久状态机的核心问题

23.1 高层一次操作, 底层多次写

假设 `append/create` 需要更新:

$$W_1 = \text{bitmap}, \quad W_2 = \text{inode}, \quad W_3 = \text{directory/data}.$$

设备只能在时间上逐步持久化它们, 崩溃可以发生在任意两步之间。因此我们要的是:

after reboot, on-disk state must correspond to a legal filesystem state

而不是假设“一次系统调用天然就是一次原子磁盘事务”。




图 9: Crash consistency 的数学对象不是单个写, 而是“多写序列 + 任意崩溃点”。

23.2 崩溃分析五步法

Crash Point Analysis

1. 列出高层操作会修改的所有持久对象；
2. 写出允许/要求的持久化顺序；
3. 标出 commit point 或“完成”的判据；
4. 在每两次持久写之间插入 crash；
5. 对每个 crash state 问：哪些结构互相矛盾？重启后是 ignore、redo、undo 还是 repair？

24 第 17 章：fsck 与 Journaling

24.1 fsck：允许不一致，重启后扫描修复

早期思路可以概括为：正常运行不维护完整事务日志，crash 后遍历 inode、bitmap、目录等结构，检查引用数、空间使用与对象关系是否自洽，再修复。

优势：运行时机制简单。代价：大文件系统全盘检查慢，而且“修复到一致”不一定等价于恢复用户最期望的最近状态。

24.2 Journaling：先记录一笔可重放的事务

经典 write-ahead logging 思路：

Log Records → Commit → Checkpoint/Home Locations

只有看到有效 commit 的事务才视为已提交；重启时可以根据日志 replay 已提交但尚未 checkpoint 完成的修改。

工程边界：ext4/JBD2

ext4 使用 jbd2 journal 保护文件系统免于元数据更新中途崩溃造成结构不一致。官方文档说明：事务完整写入并有 commit record 后，可在恢复时 replay；默认 data=ordered 模式主要 journal metadata，并要求相关 data 在 metadata commit 前按规则写出。这是一种现代实现实例，不应替代 408 对 journaling/WAL 一般机制的理解。

24.3 Consistency 与 Durability 不完全是一件事

- **Consistency**：磁盘上的结构彼此不矛盾、符合文件系统不变量；
- **Durability/Freshness**：应用刚写的数据到底已经持久到什么程度。

文件系统可以在 crash 后结构一致，但丢失最近尚未达到持久边界的数据。因此 write() 返回、后台 writeback、journal commit、fsync() 完成、设备 cache flush 是不同层次的时间点。

25 Part VII：408 计算与解题工具箱

26 第 18 章：经典计算模型

26.1 模型 A：最大文件大小

步骤：

- 1. 求索引块地址项数 $K = B/a$;
- 2. 分别计算 direct、single、double、triple 能覆盖的数据块数;
- 3. 相加后乘块大小;
- 4. 检查题目是否还有 inode 本身大小、最大文件长度字段、编号位宽等额外限制。

26.2 模型 B：判断目标字节属于哪一级索引

先：

$$LBN = \left\lfloor \frac{x}{B} \right\rfloor.$$

再与区间比较：

$$[0, d), \quad [d, d + sK), \quad [d + sK, d + sK + qK^2), \dots$$

确定索引级别，然后计算对应索引项序号。

26.3 模型 C：磁盘 I/O 次数

任何次数题先写假设表：

对象	题设状态
目录块/dentry	在内存？需要逐级读盘？
inode	已在内存？
间接索引块	已缓存？
数据页/页缓存	hit 还是 miss？
FAT	是否假设常驻内存？
写回	题目只算逻辑读取，还是连 metadata/writeback 都算？

不写这些前提就直接报一个 I/O 次数，通常是不严谨的。

26.4 模型 D：路径查找 I/O

不要机械说 /a/b/c 就一定 3 次或 6 次。路径解析可能涉及每一级目录 inode、目录数据块以及目标 inode；缓存与题设会极大改变次数。正确方法是画访问序列，再按“哪些对象已在内存”删除对应磁盘 I/O。

27 第 19 章：高频辨析表

容易混淆	错误心智模型	正确判断
inode vs filename	inode 里面存文件名	名字属于目录项；inode 表示对象元数据
directory entry vs dentry	两个完全同义	前者可指磁盘目录记录；Linux dentry 是内存 VFS 对象
fd vs inode	fd 就是文件	fd 是进程句柄，先指向 OFD
OFD vs inode	同文件只存在一个 OFD	每次独立 open 可产生独立 OFD，共享同 inode
link count vs open ref	nlink=0 立刻释放数据	仍有打开引用时内容继续存活
file offset vs PBN	offset/B 就是磁盘块	先得到 LBN，再经 block mapping
页缓存 vs block map	先求 PBN 才能查缓存	buffered file cache 更自然按 file mapping + page index 组织
FS block vs sector	文件系统块就是设备最小原子写	FS block、sector、atomic write unit 是不同概念
write return vs durable	write 返回就永久落盘	buffered write、writeback、commit、durability 分层
classic inode vs ext4	ext4 就固定 12+1+1+1	408 经典模型保留；现代 ext4 常用 extents

28 第 20 章：文件系统十四问——解题检查表

遇到任何文件系统题，按顺序扫描

1. 输入给的是 pathname 还是 fd?
2. 当前操作的是名字 (namespace) 还是已经打开的对象?
3. pathname 从 root、cwd 还是 dirfd 开始?
4. 题目中的“目录项”是持久 entry 还是内存 dentry?
5. fd 指向哪个 OFD? 是否与别的 fd 共享?
6. 当前 file offset 在哪里保存，怎样变化?
7. byte offset 属于哪个 LBN / file page index?
8. 页缓存是否命中?
9. 若需要存储访问，LBN 怎样映射到 block?
10. 使用连续、链接/FAT、索引还是混合索引? 索引块是否缓存?
11. 是否需要分配新 inode/block? 空闲空间由什么结构管理?
12. 这次操作会修改哪些 metadata 与 data?
13. 如果 crash 发生在任意两次持久写之间，状态是否合法?
14. 最终题目问的是逻辑状态、生命周期、空间、I/O 次数还是持久性?

29 第 21 章：五道综合题，把整册重新跑一遍

综合题 1：一个名字的一生

`/home/x/a.txt` $\rightarrow$ component walk $\rightarrow$ dentry/directory lookup $\rightarrow$ inode/object.

训练：目录、路径、VFS、mount、link。

综合题 2：一次 open() 的一生

Path $\rightarrow$ *Object* $\rightarrow$ *OFD* $\rightarrow$ *fd*.

训练：VFS、fd、offset、independent open/fork/dup。

综合题 3：一次 read() 的文件系统路径

fd $\rightarrow$ *OFD* $\rightarrow$ (*file, offset*) $\rightarrow$ *PageCache* $\rightarrow$ *BlockMapping* $\rightarrow$ *I/O System*.

训练：引用链、offset、缓存、索引计算与专题边界。

综合题 4：unlink 一个仍被打开的文件

训练：Name ≠ Object、链接计数、打开引用与最终回收。

综合题 5：create/write 过程中突然 crash

训练：bitmap、inode、directory、data 多结构更新，崩溃点分析，fsck/journaling。

三条核心结论

文件系统最值得记住的不是某个 inode 字段，而是三句话：

1. Naming is mapping: 名字只是到对象的引用，不等于对象本身。

2. Open is state: 打开以后必须有独立的运行时访问状态，因此 fd、OFD、inode 必须分层。

3. Persistence is protocol: 高层一次操作会变成多个持久写，正确性来自写序、提交与恢复协议，而不是“磁盘自己不会坏”。

Name → Object → Open State → Data Mapping → Persistent Protocol

30 附录 A：考试模型 / 机制 / 工程边界

主题	考试模型	机制深化	工程边界
文件抽象	文件、元数据、inode/FCB、操作、保护	object identity、metadata/data split	VFS inode operations
目录	树形目录、路径、操作、硬/软链接	pathname state machine	dcache、negative dentry、openat
打开文件	open/close/read/write、共享	fd→OFD→inode	Linux struct file/files_struct
物理结构	contiguous/linked/indexed	mixed indexing、I/O path	extents/delayed allocation
空间管理	bitmap/free list/grouping 等	locality/range allocation	ext4 block groups
文件系统	layout、VFS、mounting	namespace vs filesystem instance	VFS core objects
持久性	理解写回与一致性思想	fsck/journaling/crash points	JBD2 / ext4 data modes

31 附录 B：参考资料与工程边界

正文以 408 教材模型为主，以下公开资料用于核对术语和工程实现边界：

- Linux Kernel Documentation, *Overview of the Linux Virtual File System*: <https://docs.kernel.org/filesystems/vfs.html>
- Linux Kernel Documentation, *ext4 Data Structures and Algorithms*: <https://docs.kernel.org/filesystems/ext4/>
- Linux Kernel Documentation, *ext4 Journal (jbd2)*: <https://docs.kernel.org/6.17/filesystems/ext4/journal.html>
- POSIX.1-2024, *open(), dup(), fork()*: <https://pubs.opengroup.org/onlinepubs/9799919799/>

- OSTEP, *File System Implementation 与 Crash Consistency: FSCK and Journaling*: <https://pages.cs.wisc.edu/~remzi/OSTEP/>