

参数估计与假设检验


用抽样分布校准逆向推断：从样本观察倒推总体参数

数学一 · 概率统计 Topic 08

母问题：用抽样分布校准逆向推断：从样本观察倒推总体参数

概率论是已知总体推导样本性质；数理统计是已知样本倒推总体参数 θ 。点估计寻找最合理的数值响应，区间估计寻找高置信包络，假设检验在原假设下建立小概率拒绝界限。

主线推演逻辑：



1 本册定位与职责划分

- **本册拥有 (Owns)**：矩估计法、极大似然估计法 (MLE)、估计量的无偏性/有效性/一致性、置信区间 (枢轴变量法)、单/双正态总体的参数区间估计、假设检验的基本思想、两类错误 (第一类错误 α 与第二类错误 β)、单/双侧 $Z/t/\chi^2/F$ 检验。
- **本册使用 (Uses)**：抽样分布提供的 Z, t, χ^2, F 标尺。
- **本册不拥有 (Does not own)**：贝叶斯参数估计 (非考纲主干)。
- **输出目标 (Output)**：完整的参数逆向推断与考场统计推断题求解算子。

2 第一层：矩估计与极大似然的结构边界

2.1 矩估计的方程与信息损失

若 k 个未知参数为 $\theta_1, \dots, \theta_k$ ，取前 k 个总体原点矩

$$m_j(\theta) = E_{\theta}(X^j), \quad j = 1, \dots, k,$$

用样本矩 $A_j = n^{-1} \sum_i X_i^j$ 替代，解

$$m_j(\hat{\theta}) = A_j, \quad j = 1, \dots, k.$$

矩估计只使用有限个矩，计算通常简单但可能不唯一、超出参数空间或效率较低。正态模型中 $\hat{\mu} = \bar{X}$ 、 $\hat{\sigma}^2 = B_2$ ；后者是矩估计而不是无偏样本方差。

2.2 似然不是概率，支撑集先于求导

固定观测 $\mathbf{x}$ 后，似然函数是参数的函数：

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f_{\theta}(x_i) \quad \text{或} \quad \prod_{i=1}^n p_{\theta}(x_i).$$

它不是关于 θ 的概率分布，也不需要 θ 积分为 1。可用对数似然

$$\ell(\theta) = \log L(\theta),$$

但最大化必须在参数空间与观测可行域上完成。

固定支撑且内部极值时，可解得分方程 $\ell'(\theta) = 0$ 并检查二阶导数；参数相关支撑时，必须先写

$$L(\theta; \mathbf{x}) = 0 \quad \text{当 } \mathbf{x} \notin \mathcal{S}_{\theta},$$

再检查边界。例： $U(0, \theta)$ 的似然在 $\theta \geq x_{(n)}$ 上与 θ^{-n} 成正比，故 $\hat{\theta}_{MLE} = X_{(n)}$ ，不是由内部求导得到。

MLE 的不变性：若 $\hat{\theta}$ 最大化 $L(\theta)$ ，则一一变换 $g(\hat{\theta})$ 最大化关于 $g(\theta)$ 的似然；非一一变换也取 $g(\hat{\theta})$ ，但必须枚举所有原像的最大值，不能把逆函数假设为唯一。

充分统计量 $T(X)$ 的因子分解准则是：联合密度可写为

$$f_{\theta}(\mathbf{x}) = g_{\theta}(T(\mathbf{x}))h(\mathbf{x}).$$

它说明样本关于 θ 的似然信息被 T 保留；充分性与 MLE、UMVU 有接口，但不是“任何估计量都自动最优”。

2.3 三个代表性点估计模型

观测变换后的三步重建

若题目没有给出原始观测 X_i ，而只记录 $Z_i = g(X_i)$ ，估计参数前必须重建 Z 的观测模型：

1. 写出 Z 的支撑，并枚举 $g(x) = z$ 的全部原像；
2. 由 CDF 原像法或密度变换得到 $f_Z(z; \theta)$ ，检查其积分为 1；
3. 只对这个新密度建立矩方程或似然方程，并检查参数边界。

因此原正态样本的均值、方差公式不能直接套到绝对误差 $Z_i = |X_i - \mu|$ 上；正是两条原像分支共同决定了半正态密度、矩估计和 MLE。

指数率参数：矩估计与 MLE 相同

若 $X_i \sim \text{Exp}(\lambda)$ ，密度为 $\lambda e^{-\lambda x} I_{x>0}$ ，则 $E(X) = 1/\lambda$ 。矩方程给出 $\hat{\lambda}_{MOM} = 1/\bar{X}$ ；对数似然

$$\ell(\lambda) = n \log \lambda - \lambda \sum_i x_i$$

的内部极值也给出 $\hat{\lambda}_{MLE} = n / \sum_i x_i = 1/\bar{X}$ 。这里支撑与 λ 无关，求导合法；其方差、相合性仍需另行评价。

Bernoulli: 似然的计数压缩

若 $X_i \sim \text{Bern}(p)$, 则 $L(p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$, 所以

$$\hat{p}_{MLE} = \bar{X}.$$

它同时是无偏、相合估计量; $n\bar{X} \sim \text{Bin}(n, p)$ 是此模型的充分统计量。若题面出现全为 0 或全为 1, MLE 仍在参数空间边界 0 或 1, 不能因为得分方程没有内部解而否定它。

正态总体: 矩估计、MLE 与无偏修正分流

对 $N(\mu, \sigma^2)$, 矩估计与 MLE 为

$$\hat{\mu} = \bar{X}, \quad \hat{\sigma}_{MOM}^2 = \hat{\sigma}_{MLE}^2 = B_2.$$

但无偏估计方差要使用

$$S^2 = \frac{n}{n-1} B_2.$$

这三个量的公式相似、职责不同: MLE 最大化样本似然, MOM 匹配总体矩, S^2 追求无偏性。

2007 真题: 参数进支撑时先分段求矩

设

$$f(x; \theta) = \frac{1}{2\theta} I_{(0, \theta)}(x) + \frac{1}{2(1-\theta)} I_{[\theta, 1)}(x), \quad 0 < \theta < 1.$$

不能看到分段密度就直接套固定支撑公式, 必须先沿支撑分段积分:

$$E(X) = \frac{\theta}{4} + \frac{1+\theta}{4} = \frac{1+2\theta}{4},$$

故矩估计为 $\hat{\theta}_{MOM} = 2\bar{X} - \frac{1}{2}$ 。同时

$$E(X^2) = \frac{1+\theta+2\theta^2}{6},$$

所以

$$E(4\bar{X}^2) = 4 \left([E(X)]^2 + \frac{\text{Var}(X)}{n} \right)$$

含有样本量相关的方差项, 不能恒等于 θ^2 ; 例如 $\theta = 1/2$ 时它等于 $1 + 1/(3n)$ 。矩估计方程与无偏性检验必须分开。

2010 真题: 频数先压缩成二项指标

总体取值 1, 2, 3 的概率为

$$P(X=1) = 1-\theta, \quad P(X=2) = \theta-\theta^2, \quad P(X=3) = \theta^2.$$

若 N_i 是容量为 n 的样本频数, 则 $N_2 + N_3$ 统计“样本值是否至少为 2”, 因而

$$N_2 + N_3 \sim \text{Bin}(n, \theta).$$

目标参数的最短表示是

$$T = \frac{N_2 + N_3}{n}, \quad E(T) = \theta, \quad \text{Var}(T) = \frac{\theta(1-\theta)}{n}.$$

若从 $T = \sum a_i N_i$ 的系数方程出发, 则 $a_1 = 0$ 、 $a_2 = a_3 = 1/n$ 。这体现了“先找与参数直接对应的事件, 再把频数压缩”为二项指标; 不能遗漏容量归一化。

2.4 参数相关支撑的边界型 MLE

对 $U(0, \theta)$,

$$L(\theta) = \theta^{-n} I\{\theta \geq X_{(n)}\}, \quad \hat{\theta}_{MLE} = X_{(n)}.$$

对 $U(a, b)$, 可行域要求 $a \leq X_{(1)}$ 、 $b \geq X_{(n)}$; 似然与 $(b-a)^{-n}$ 成正比, 若参数空间允许, MLE 通常在样本极值处取得: $\hat{a} = X_{(1)}$ 、 $\hat{b} = X_{(n)}$ 。对 $U(\theta, 2\theta)$, 可行域为 $X_{(n)}/2 \leq \theta \leq X_{(1)}$, 最大化 θ^{-n} 需选择可行域左端 $\hat{\theta} = X_{(n)}/2$ 。这些例子共同说明: 先求可行域, 再判断边界方向。

2015 真题: $U(\theta, 1)$ 的矩估计与边界 MLE

若 $X_i \stackrel{\text{i.i.d.}}{\sim} U(\theta, 1)$, 则

$$E(X) = \frac{\theta + 1}{2}, \quad \hat{\theta}_{MOM} = 2\bar{X} - 1.$$

固定观测后, 参数必须满足 $\theta \leq X_{(1)}$, 且

$$L(\theta) = \frac{1}{(1-\theta)^n} I\{\theta \leq X_{(1)}\}.$$

在可行域上 $L(\theta)$ 随 θ 增大而增大, 所以

$$\hat{\theta}_{MLE} = X_{(1)}.$$

矩估计是用总体均值反解, MLE 是在参数相关支撑的边界上最大化; 看到均匀区间含未知端点, 第一动作必须是写可行域, 不能先对数似然求导。

2004 真题: Pareto 型总体的 MOM 与 MLE 分流

设

$$F(x; \beta) = \begin{cases} 1 - x^{-\beta}, & x > 1, \\ 0, & x \leq 1, \end{cases} \quad \beta > 1.$$

先由尾积分求一阶矩:

$$E(X) = \int_1^\infty x \beta x^{-\beta-1} dx = \frac{\beta}{\beta-1}.$$

用样本均值匹配总体均值, 矩估计满足

$$\bar{X} = \frac{\hat{\beta}_{MOM}}{\hat{\beta}_{MOM} - 1} \implies \hat{\beta}_{MOM} = \frac{\bar{X}}{\bar{X} - 1}.$$

固定观测后, 密度为 $f(x; \beta) = \beta x^{-\beta-1} I_{\{x>1\}}$, 支撑与 β 无关, 故

$$\ell(\beta) = n \ln \beta - (\beta + 1) \sum_{i=1}^n \ln x_i.$$

得分方程给出

$$\ell'(\beta) = \frac{n}{\beta} - \sum_{i=1}^n \ln x_i = 0 \implies \hat{\beta}_{MLE} = \frac{n}{\sum_{i=1}^n \ln X_i}.$$

且 $\ell''(\beta) = -n/\beta^2 < 0$, 确为全局极大值; 若观测全大于 1, 估计值自动为正。两条结果通常不同: MOM 使用 $\bar{X}$, MLE 使用 $\sum \ln X_i$, 不能由“目标都是估计 β ”互相替代。

2014 真题: Rayleigh 型尺度的 MLE 与相合性

题面给出

$$F(x; \theta) = \begin{cases} 1 - e^{-x^2/\theta}, & x \geq 0, \\ 0, & x < 0, \end{cases} \quad \theta > 0.$$

先对 x 求导得到观测密度

$$f(x; \theta) = \frac{2x}{\theta} e^{-x^2/\theta} I_{\{x \geq 0\}}.$$

令 $S = \sum_{i=1}^n X_i^2$, 则

$$\ell(\theta) = -n \ln \theta - \frac{S}{\theta} + \sum_i \ln(2X_i).$$

在 $\theta > 0$ 上,

$$\ell'(\theta) = -\frac{n}{\theta} + \frac{S}{\theta^2} = 0 \implies \hat{\theta}_n = \frac{S}{n}.$$

令 $U = X^2$ 。由题给尾分布, $P(U \leq u) = 1 - e^{-u/\theta}$ ($u \geq 0$), 故 $U \sim \text{Exp}(1/\theta)$, 从而

$$E(X^2) = E(U) = \theta, \quad \text{Var}(X^2) = \text{Var}(U) = \theta^2.$$

所以

$$E(\hat{\theta}_n) = \theta, \quad \text{Var}(\hat{\theta}_n) = \frac{\theta^2}{n}, \quad \hat{\theta}_n \xrightarrow{P} \theta$$

(最后一步用大数定律)。这三句分别是有限样本无偏、方差表达式和相合性, 不能由“求出 MLE”自动合并推出。

第三小问的原文写成“是否存在实数 a , 使对任意 $\varepsilon > 0$, $P\{|\hat{\theta}_n| \geq \varepsilon\} \rightarrow 0$ ”。按字面, a 没有进入事件, 问题实际是在问 $\hat{\theta}_n \xrightarrow{P} 0$ 是否成立。由于

$$\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i^2 \xrightarrow{P} \theta, \quad \theta > 0,$$

取 $\varepsilon = \theta/2$, 则 $P\{|\hat{\theta}_n| \geq \varepsilon\} \rightarrow 1$, 所以不存在这样的 a 。

来源边界: 若原图实际想写的是 $P\{|\hat{\theta}_n - a| \geq \varepsilon\} \rightarrow 0$, 那是另一条命题; 对固定参数值它等价于 $a = \theta$, 但不能把这个可能的缺字擅自替换进标准答案。当前正文只报告原式的字面结论, 并保留 source-anomaly 标记。

3 第二层: 估计量评价的三种尺度

对估计量 $\hat{\theta}$, 偏差、方差和均方误差分别为

$$b(\theta) = E_{\theta}(\hat{\theta}) - \theta, \quad \text{MSE}_{\theta}(\hat{\theta}) = E_{\theta}[(\hat{\theta} - \theta)^2],$$

$$\boxed{\text{MSE}(\hat{\theta}) = \text{Var}(\hat{\theta}) + b(\theta)^2}.$$

无偏是偏差为零的性质, 不是所有决策下的“最好”。有偏估计量可能以显著降低方差换取更小 MSE; 比较估计量时必须先说明比较域 (所有估计量、无偏估计量或固定参数点)。

MSE 分解的计算推导

令 $b(\theta) = E_\theta(\hat{\theta}) - \theta$ ，把误差拆成

$$\hat{\theta} - \theta = (\hat{\theta} - E_\theta \hat{\theta}) + b(\theta).$$

平方取期望时，第一项均值为零，交叉项消失，因而

$$E_\theta[(\hat{\theta} - \theta)^2] = \text{Var}_\theta(\hat{\theta}) + b(\theta)^2.$$

这解释了为什么“有偏”不能单独判废估计量：必须回到题目指定的损失或比较标准。

2024 真题：同一统计量的无偏目标与 MSE 目标必须分开

设 $X_i \stackrel{\text{i.i.d.}}{\sim} U(0, \theta)$ ，令 $T = X_{(n)}$ 。顺序统计量的分布与矩由 P07 负责；这里只接收其接口

$$E(T) = \frac{n}{n+1}\theta, \quad E(T^2) = \frac{n}{n+2}\theta^2.$$

若题目要求 cT 无偏，目标方程是 $E(cT) = \theta$ ，故

$$c_{\text{unb}} = \frac{n+1}{n}.$$

若题目改为使 $E[(cT - \theta)^2]$ 最小，则必须保留偏差项并直接最小化

$$h(c) = E[(cT - \theta)^2] = c^2 E(T^2) - 2c\theta E(T) + \theta^2.$$

令 $h'(c) = 0$ 得

$$c_{\text{MSE}} = \frac{E(T)}{E(T^2)}\theta = \frac{n+2}{n+1}, \quad \min h(c) = \frac{\theta^2}{(n+1)^2}.$$

因此 $c_{\text{unb}} \neq c_{\text{MSE}}$ ：前者满足约束 $b(\theta) = 0$ ，后者优化平方损失；看到“无偏”或“最小均方误差”必须先圈出目标词，不能沿用上一小问的系数。

若 $E_\theta(\hat{\theta}) = c\theta$ 且 $c \neq 0$ ，可用 $\hat{\theta}/c$ 做线性偏差修正；但一般偏差未必是参数的常数倍，不能看到“有偏”就机械乘一个系数。渐近无偏只表示 $E_\theta(\hat{\theta}_n) \rightarrow \theta$ ，仍不同于有限样本无偏和相合性。

推断输出契约：不要在子问之间偷换目标

参数推断题先标注本小问要交付的对象：

目标 → 信息与支撑 → 构造/评价/反演算子 → 边界证据 → 结论

构造估计量时检查参数域与观测可行域；判断无偏或相合时分别取期望或极限；比较估计量时按题目指定的偏差、方差或 MSE；区问题报告覆盖率和尾部；检验题先固定 H_0, H_1 ，再区分在 H_0 下校准的第一类错误与在具体备择参数下计算的第二类错误。完成一个目标后不能自行改换评价标准：无偏系数不等于最小 MSE 系数，不拒绝也不等于接受。

若两个无偏估计量比较方差，方差较小者更有效；相对效率可写为方差比。UMVU 指在所有无偏估计量中对每个参数都具有最小方差，通常依赖充分完备统计量，而不是只看一次样本。

Fisher 得分与信息为

$$U(\theta) = \frac{\partial}{\partial \theta} \ell(\theta), \quad I_n(\theta) = E_\theta[U(\theta)^2] = -E_\theta \left[\frac{\partial^2}{\partial \theta^2} \ell(\theta) \right]$$

(等式需正则条件)。Cramér–Rao 下界：对无偏估计量 $\hat{\theta}$ ，在固定支撑、可交换微分与积分等正则条件下，

$$\boxed{\text{Var}_\theta(\hat{\theta}) \geq \frac{1}{I_n(\theta)}}.$$

向量参数时为 $\text{Cov}(\hat{\theta}) \succeq I_n(\theta)^{-1}$ 。支撑含参、边界非光滑或信息不存在时，不能机械套 Cramér–Rao。

Rao–Blackwell：若 T 充分， $E(\hat{\theta} | T)$ 的 MSE 不大于 $\hat{\theta}$ ；Lehmann–Scheffé：若 T 充分完备且 $h(T)$ 无偏，则 $h(T)$ 是 UMVU。它们分别是“条件化降噪”和“充分完备唯一化”，不可与无偏性或相合性混同。

3.1 评价例： B_2 与 S^2

在 $E(X^2) < \infty$ 时， B_2 的偏差为 $-\sigma^2/n$ ，而 S^2 无偏。若四阶中心矩存在，

$$\text{MSE}(B_2) = \text{Var}(B_2) + \frac{\sigma^4}{n^2},$$

不能只因 B_2 有偏就断言它在 MSE 下更差。比较必须指定总体、样本量和损失标准；无偏性是一个约束，不是唯一目标。在正态总体下还可进一步写出

$$\text{MSE}(B_2) = \frac{2n-1}{n^2} \sigma^4, \quad \text{MSE}(S^2) = \frac{2}{n-1} \sigma^4,$$

这说明“无偏”与“MSE 更小”是两个不同的评价问题。

4 第三层：相合性与渐近正态性

弱相合指 $\hat{\theta}_n \xrightarrow{P} \theta$ ，强相合指 $\hat{\theta}_n \xrightarrow{a.s.} \theta$ 。常用证明路线：

1. 写成样本矩或样本均值，使用 Topic 06 的大数定律；
2. 用连续映射定理处理函数；
3. 或证明 $\text{MSE}(\hat{\theta}_n) \rightarrow 0$ ，再用 Chebyshev。

无偏不推出相合，有限样本有效也不推出相合；相合也不保证有限样本无偏。若

$$\sqrt{n}(\hat{\theta}_n - \theta) \xrightarrow{d} N(0, V(\theta)),$$

则称渐近正态， $V(\theta)$ 是渐近方差；再比较渐近方差才谈渐近效率。MLE 在正则模型下常满足渐近正态，但参数相关支撑或边界参数可能出现非正态、非 $\sqrt{n}$ 速率。

5 第四层：区间估计是枢轴量的反演

置信区间是随机区间 $C(X)$ ，要求对固定参数满足

$$P_\theta\{\theta \in C(X)\} = 1 - \alpha.$$

频率解释是“重复抽样生成的区间有 $1-\alpha$ 的长期覆盖率”，不是“本次固定参数落在区间内的概率为 $1-\alpha$ ”。

通用构造：找分布不含未知参数的枢轴量 $G(X; \theta)$ ，取

$$P(a \leq G(X; \theta) \leq b) = 1 - \alpha,$$

再对不等式反解 θ 。尾部如何分配会影响区间长度；对称分位点不是所有参数空间都最优。

区间估计的证据链

先确认 $G(X; \theta)$ 的分布确实不含未知参数，再写出覆盖概率等式；最后只对不等式做等价反解，并记录尾部方向。这样得到的是随机区间 $C(X)$ 的重复抽样覆盖率，不是给定观测后参数的后验概率。若枢轴只是在大样本下近似无参数，区间也必须标为渐近区间。

5.1 单正态总体

若 $X_i \sim N(\mu, \sigma^2)$:

$$\sigma \text{ 已知: } \mu \in \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right];$$

$$\sigma \text{ 未知: } \mu \in \left[\bar{X} - t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}}, \bar{X} + t_{\alpha/2}(n-1) \frac{S}{\sqrt{n}} \right].$$

方差区间由 $Q = (n-1)S^2/\sigma^2 \sim \chi^2(n-1)$ 反解:

$$\left[\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right].$$

由于卡方分布右偏，上下分位点位置不能按正态对称习惯书写。标准差区间是对方差区间逐端取平方根。

5.2 双总体、配对与单侧界

两独立正态总体均值差在方差已知时使用 Z ；等方差未知时使用合并方差 t ；方差不等时用 Welch 近似；配对数据先对差值构造单样本区间。方差比使用

$$\frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1).$$

单侧置信限只把全部 α 放在一个尾部，不能把双侧 $\alpha/2$ 直接照搬。

5.3 两总体均值差的区间

两独立正态总体均值差 $\Delta = \mu_1 - \mu_2$:

$$\sigma_1^2, \sigma_2^2 \text{ 已知: } \Delta \in \left[(\bar{X} - \bar{Y}) - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, (\bar{X} - \bar{Y}) + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right].$$

等方差未知时将标准误换为 $S_p \sqrt{1/n_1 + 1/n_2}$ ，分位点换为 $t_{\alpha/2}(n_1 + n_2 - 2)$ ；不等方差使用 Welch-Satterthwaite 自由度。配对区间则对 $D_i = X_i - Y_i$ 使用 $\bar{D} \pm tS_D/\sqrt{n}$ 。

方差比 $R = \sigma_1^2/\sigma_2^2$ 的区间由

$$Q = \frac{S_1^2/S_2^2}{R} \sim F(n_1-1, n_2-1)$$

反解：

$$\frac{S_1^2/S_2^2}{F_{\alpha/2}(n_1-1, n_2-1)} \leq R \leq \frac{S_1^2/S_2^2}{F_{1-\alpha/2}(n_1-1, n_2-1)}.$$

分位点记号若采用下分位点约定，必须先换成统一的上尾约定，不能混用表格。

5.4 扩展与边界

Wald 区间用渐近正态替换枢轴量，比例接近边界时可能越出 $[0, 1]$ ；Bootstrap 用重抽样近似抽样分布，需说明它是近似方法而非自动精确。区间长度随标准误、分位点和置信水平变化；样本量增大通常缩短长度，但偏差、重尾和模型误设仍会影响覆盖率。

6 第五层：假设检验的校准机制

原假设 H_0 与备择 H_1 划分参数空间。等号通常放在 H_0 ，因为拒绝域的概率在 H_0 下校准。检验统计量 T 与拒绝域 W 的关系是： $T \in W$ 时拒绝 H_0 ，否则不拒绝 H_0 。

第一类错误（弃真）概率为

$$\alpha(\theta) = P_\theta(T \in W), \quad \theta \in \Theta_0,$$

检验尺寸是 $\sup_{\theta \in \Theta_0} \alpha(\theta)$ ；第二类错误为 $\beta(\theta) = P_\theta(T \notin W)$ ，功效函数为

$$\pi(\theta) = P_\theta(T \in W) = 1 - \beta(\theta), \quad \theta \in \Theta_1.$$

固定样本量下，缩小 α 往往会降低功效；增大样本量通常可同时提高给定偏离下的功效。不得把“不拒绝 H_0 ”写成“证明 H_0 正确”。

6.1 方向、分位点与 p 值

$H_1: \theta > \theta_0$ 使用右尾， $H_1: \theta < \theta_0$ 使用左尾， $H_1: \theta \neq \theta_0$ 使用双尾；方向由备择假设决定，不由样本结果倒选。 p 值是在 H_0 下得到“不少于当前观测极端”的概率，必须在检验方向和统计量定义固定后计算； $p \leq \alpha$ 才拒绝 H_0 。

6.2 正态总体的基本检验枢轴

单总体均值：

$$Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1) \quad (\sigma \text{ 已知}),$$

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t(n-1) \quad (\sigma \text{ 未知, 正态总体}).$$

单总体方差：

$$Q = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi^2(n-1).$$

两独立总体均值差按方差已知、等方差未知、不等方差三路分流；配对样本对差值作 t 检验；方差比使用 F 。任何公式都必须同步写明正态性、独立性、方差假设和自由度。

6.3 拒绝域与 p 值的具体形状

对单总体均值 $H_0: \mu = \mu_0$:

- 右侧 $H_1: \mu > \mu_0$: $Z > z_\alpha$ 或 $T > t_\alpha(n-1)$;
- 左侧 $H_1: \mu < \mu_0$: $Z < -z_\alpha$ 或 $T < -t_\alpha(n-1)$;
- 双侧 $H_1: \mu \neq \mu_0$: $|Z| > z_{\alpha/2}$ 或 $|T| > t_{\alpha/2}(n-1)$ 。

若 $H_0: \sigma^2 = \sigma_0^2$, 使用 $Q = (n-1)S^2/\sigma_0^2$; 右侧拒绝 $Q > \chi_\alpha^2(n-1)$, 左侧拒绝 $Q < \chi_{1-\alpha}^2(n-1)$, 双侧两端分别用 $\alpha/2$ 。方差比检验同理使用 F , 但分子、分母和备择方向固定后才决定尾部。

对应 p 值: 右尾为 $P_{H_0}(T \geq t_{obs})$, 左尾为 $P_{H_0}(T \leq t_{obs})$, 双尾对称统计量常为 $2 \min\{P_{H_0}(T \geq t_{obs}), P_{H_0}(T \leq t_{obs})\}$ 。非对称分布 (如 χ^2, F) 不能机械乘二, 应按检验的极端集合定义。

2018 真题: 显著性水平改变时先比较拒绝域

对双侧检验 $H_0: \mu = \mu_0, H_1: \mu \neq \mu_0$, 令 T 为已经确定方向的对称检验统计量。水平 0.05 与 0.01 的拒绝域分别为

$$W_{.05} = \{|T| > c_{.05}\}, \quad W_{.01} = \{|T| > c_{.01}\}, \quad c_{.01} > c_{.05}.$$

因此 $W_{.01} \subset W_{.05}$: 在 0.01 下拒绝必然在 0.05 下拒绝, 但在 0.05 下拒绝不能反推出 0.01 下仍拒绝; 同样, 0.05 下不拒绝必然推出 0.01 下不拒绝。判断检验命题的第一动作是比较拒绝域集合, 而不是把“显著性水平更小”机械翻译成“必接受”。

6.4 功效、样本量与实际意义

以已知 σ 的右侧均值检验为例, 拒绝域 $\bar{X} > \mu_0 + z_\alpha \sigma / \sqrt{n}$ 。在真实均值 $\mu_1 > \mu_0$ 下, 功效为

$$\pi(\mu_1) = 1 - \Phi\left(z_\alpha - \frac{\sqrt{n}(\mu_1 - \mu_0)}{\sigma}\right).$$

因此样本量、效应大小和噪声共同决定功效; “显著”不等于效应具有实际重要性。近似样本量计算应先指定最小有意义差异 δ 、显著性水平 α 和目标功效 $1 - \beta$, 再使用正态分位点, 不能只因题目给出 n 大就声称功效高。

2021 真题: 给定拒绝域后反推第二类错误

设 $X_i \sim N(\mu, 4)$, $n = 16$, 右侧检验的拒绝域为 $W = \{\bar{X} \geq 11\}$ 。当真实值为 $\mu = 11.5$ 时, 第二类错误是“未进入拒绝域”, 而不是在 H_0 下重新计算:

$$\beta(11.5) = P_{11.5}(\bar{X} < 11), \quad \bar{X} \sim N\left(11.5, \frac{4}{16}\right).$$

故

$$\beta(11.5) = \Phi\left(\frac{11 - 11.5}{0.5}\right) = \Phi(-1) \approx 0.1587.$$

这道题的关键是先把错误事件取为 W^c , 再用真实备择参数下的分布计算; 第一类错误用 H_0 校准, 第二类错误用具体 $\theta \in \Theta_1$ 评价。

6.5 检验语句的证据边界

拒绝 H_0 : 数据在 H_0 下足够极端, 支持 H_1 或说明与 H_0 不相容; 不能说 H_1 被概率证明。

不拒绝 H_0 : 证据不足以在当前 α 下拒绝; 可能是效应确实小, 也可能是样本量不足或噪声过大。只有预先设计等效检验或足够功效, 才可讨论“差异小到可忽略”。

7 第六层：区间—检验对偶与最强检验

双侧 $1 - \alpha$ 置信区间包含 θ_0 , 与显著性水平 α 的双侧检验“不拒绝 $H_0: \theta = \theta_0$ ”对偶; 单侧区间同样对应单侧检验。对偶关系来自同一枢轴量和同一尾部概率, 不意味着任何任意区间都对应同一检验。

Neyman–Pearson 引理在简单 H_0 对简单 H_1 下, 以似然比阈值构造给定尺寸下功效最大的检验; 广义似然比把复合假设分别最大化似然。它们是方法论接口, 不能取代具体分布下的拒绝域校准。

多重检验中逐个使用 α 会放大至少一次错误拒绝的概率; Bonferroni 等校正控制族错误率, 但会牺牲功效。单次检验的 p 值、全局显著性和实际效应大小必须分开表述。

8 第七层：统一推断工作流

1. 写清总体模型、参数空间、样本独立性和是否正态; 参数相关支撑先处理可行域。
2. 点估计选择矩匹配或似然最大化, 并检查解是否落在参数空间、是否为全局最大值。
3. 评价估计量时区分偏差、方差、MSE、相合性、有限/渐近效率; 不要只用“无偏”一票否决。
4. 区间估计先找无未知参数枢轴量, 再按正确尾部反解; 区分精确覆盖率与渐近覆盖率。
5. 检验先定 H_0/H_1 和方向, 再定统计量、拒绝域、 α 、 p 值和功效; 不因观察结果改变备择方向。
6. 结论写成“拒绝/不拒绝 H_0 ”及其参数语境, 不能写成证明或接受绝对真理。

核心反例与边界

支撑含参数时 MLE 可能在边界; 似然是参数函数而非参数概率; 无偏不推出有效、相合或低 MSE; 相合不推出无偏; $t/\chi^2/F$ 精确公式依赖正态样本; Wald/Bootstrap 是近似; 不拒绝 H_0 不是证明 H_0 ; 多重检验不能忽略整体错误率。

9 贯穿母例：Bernoulli 成功率的逆向推断

母例：从计数到估计、区间与检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bern}(p)$, 参数空间为 $0 \leq p \leq 1$, 观测成功次数为 $K = \sum_i X_i$ 。矩方程和似然最大化都给出

$$\hat{p} = \bar{X} = K/n, \quad K \sim \text{Bin}(n, p),$$

且 $E(\hat{p}) = p$, $\text{Var}(\hat{p}) = p(1-p)/n$ 。当 $0 < p < 1$ 时, Topic 06 的 CLT 提供渐近标准化

$$\frac{\sqrt{n}(\hat{p} - p)}{\sqrt{p(1-p)}} \xrightarrow{d} N(0, 1),$$

可据此构造近似区间或检验 $H_0: p = p_0$; 但 p 接近 0, 1 或 n 较小时, Wald 近似可能越界或覆盖率失真, 应回到精确二项方法或更稳健的区间。检验结论只能写“拒绝/不拒绝 H_0 ”, 不能写成证明参数真值。

10 一页压缩

一句话总结

矩估计解方程, 似然估计求最大, 枢轴变量求包络, 拒绝域控制弃真错。

绝对值观测后必须重建似然: 2017 真题

若 $X \sim N(\mu, \sigma^2)$ 且只观察 $Z = |X - \mu|$, 则 Z 服从半正态分布:

$$f_Z(z; \sigma) = \sqrt{\frac{2}{\pi}} \frac{1}{\sigma} e^{-z^2/(2\sigma^2)}, \quad z > 0.$$

因此一阶矩给 $\hat{\sigma}_{MOM} = \sqrt{\pi/2} \bar{Z}$, 似然最大化给

$$\hat{\sigma}_{MLE} = \sqrt{\frac{1}{n} \sum_{i=1}^n Z_i^2}.$$

不能把 Z_i 继续当作正态观测, 也不能沿用未知均值的正态似然。